법인 거래활동성 약화 조기탐지



1조 바로이탈잡아뿌조 | 박성준 서은표 이주희 정수민 조준연 차재혁 | 2026.06.25.

목차

01
개요
프로젝트 개요 및 목표 소개

02
EDA 및 전처리
프로젝트의 전반적 과정 소개

03
베이스 모델
변수 선정 및 적합 모델 선정 목적

04
업종별 모델
베이스 기반 세부적인 모델 제시

05
페르소나 분석
최종 모델 기반 페르소나 분석

06
제언
페르소나 기반 최종 제의

07
한계점 및 확장성
한계점 및 향후 개선 방향

08
QnA
묻고 답하기

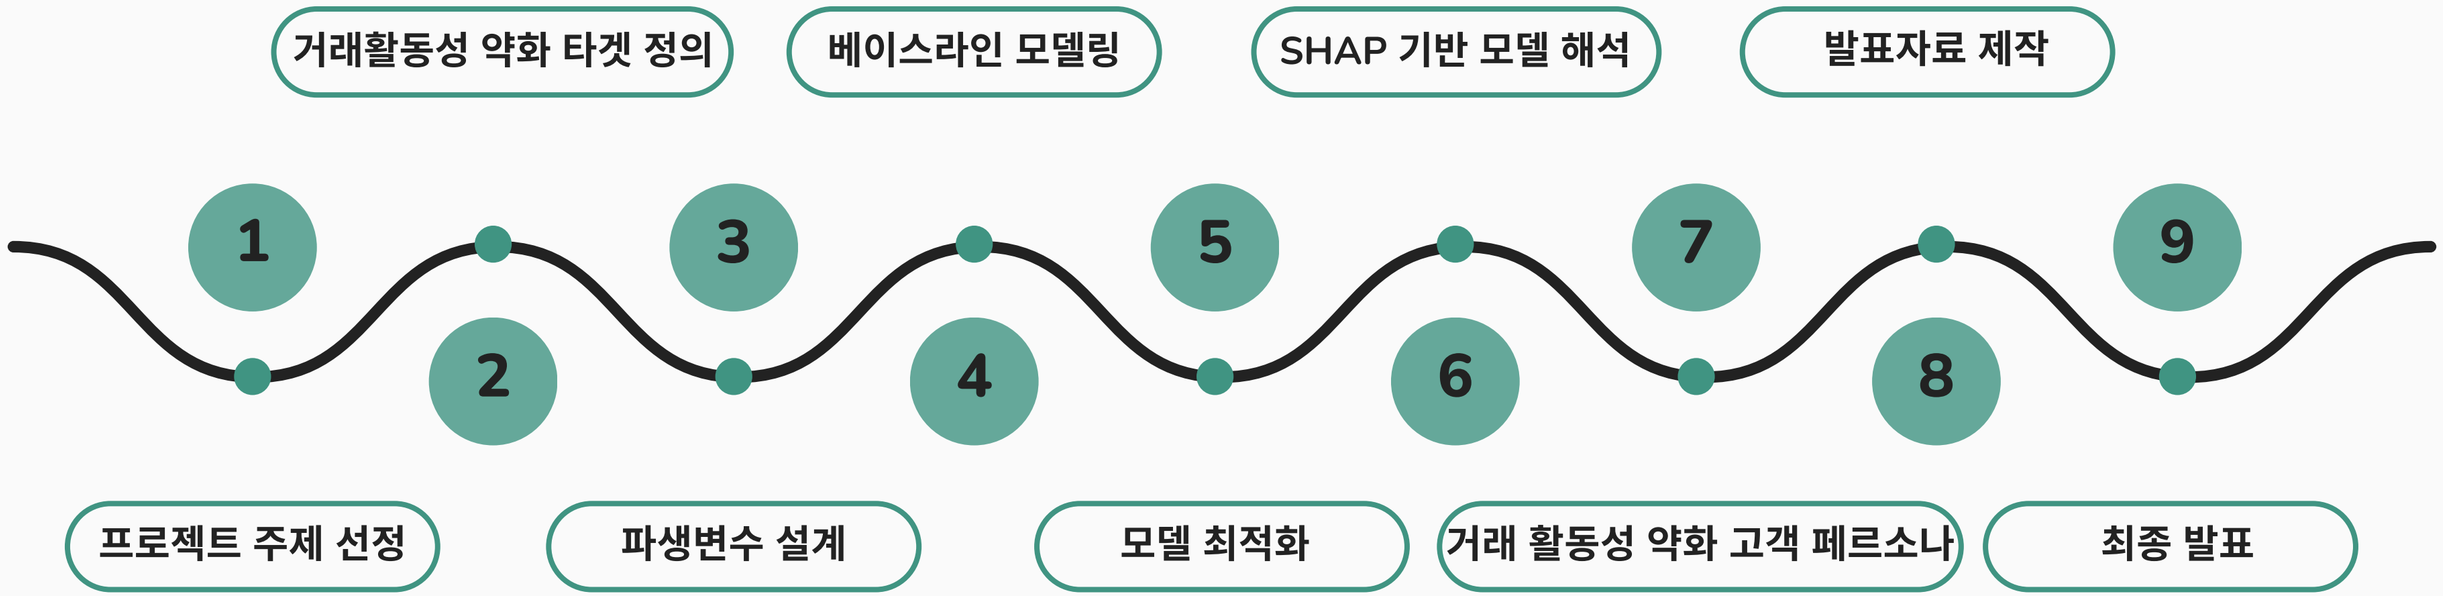
01

개요

프로젝트 개요 및 목표 소개

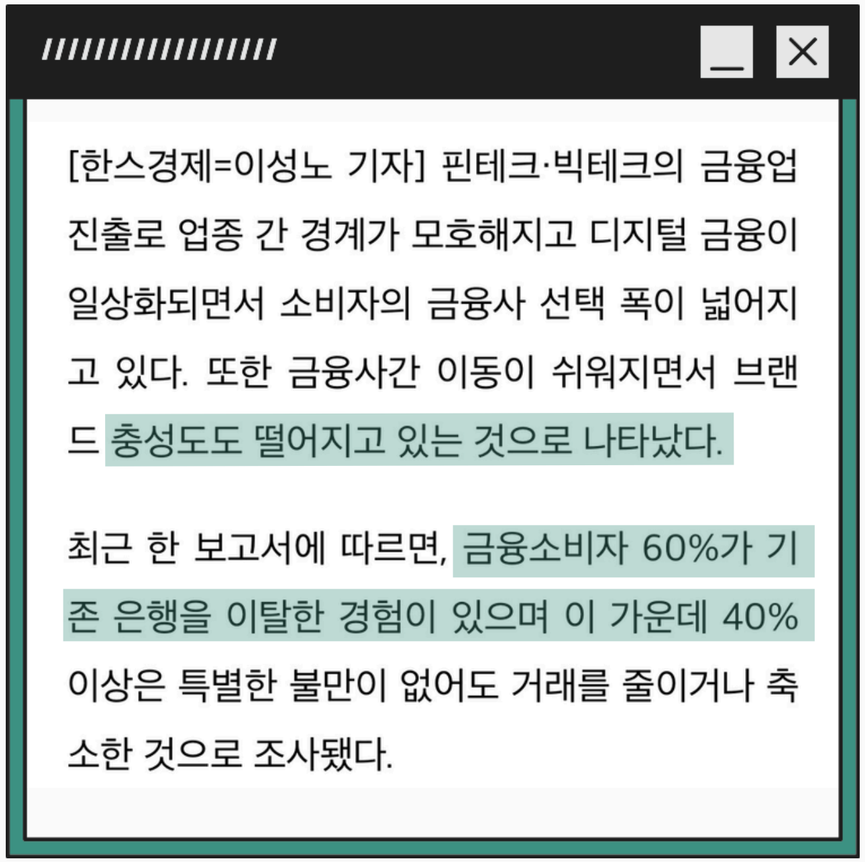
개요

2. 추진일정


거래활동성 약화 타겟 정의
베이스라인 모델링
SHAP 기반 모델 해석
발표자료 제작
1
2
3
4
5
6
7
8
9
프로젝트 주제 선정
파생변수 설계
모델 최적화
거래 활동성 약화 고객 페르소나
최종 발표

개요

3. 프로젝트 추진 배경



[한스경제=이성노 기자] 핀테크·빅테크의 금융업 진출로 업종 간 경계가 모호해지고 디지털 금융이 일상화되면서 소비자의 금융사 선택 폭이 넓어지고 있다. 또한 금융사간 이동이 쉬워지면서 브랜드 충성도도 떨어지고 있는 것으로 나타났다.

최근 한 보고서에 따르면, 금융소비자 60%가 기존 은행을 이탈한 경험이 있으며 이 가운데 40% 이상은 특별한 불만이 없어도 거래를 줄이거나 축소한 것으로 조사됐다.

출처: 한스경제, 「은행권, 타행 이탈에 충성고객 확보 분주」, 이성노 기자, 2025.06.10.

01. 은행 충성도 약화

- 금융 소비자 60%가 기존 은행 이탈 경험

02. 금융사 선택 폭 확대

- 디지털 금융 일상화
- 쉽게 금융사 간 비교, 이동

03. 거래 감소 기반 관리 필요

- 고객의 거래 변화 흐름을 분석하여 고객 활동성 약화를 조기 탐지 필요

개요

4. EDA 기반 주제 선택 이유

01



월별 거래 패턴 확인 가능

- 법인별 36개월 월별 거래 데이터 보유
- 다양한 금융 활동 변수 존재
- 시간 흐름에 따른 변화 분석 가능

02



단순 미거래 기준의 한계

- 분기 말마다 활성 고객 수 감소 현상 확인
- 그 중 다수가 다음 달 재등장
- 단기 거래 공백과 지속적 거래 공백 구분할 필요 확인

03



현실적 타겟 재설계

- 완전 이탈 고객은 거의 확인 X
- 거래 활동 감소 흐름을 거래 감소 신호로 정의

법인 고객 이탈은 '관계 종료'가 아니라 '거래 관계 약화'로 먼저 나타난다



명확한 이탈 사건의 부재

- 계좌 해지 없이 거래만 감소 가능
- 사후 확인 시 대응 지연



거래 활동 감소 신호

- 거래금액, 거래건수 감소
- 채널 이용 약화



조기 탐지 문제로 재정의

- 거래 건수 감소를 거래 활동성 약화로 정의
- 월별 거래 패턴 기반 위험 고객 탐지

개요

6. 프로젝트 분석 목표



거래 활동성 약화 정의

법인 고객의 거래건수 기반으로
거래 활동성 약화 라벨 생성



탐지 모델 구축

월별 거래 패턴과 파생변수를
활용한 거래활동성 약화 고객 탐지



인사이트 도출

SHAP 분석과 고객 페르소나를
통해서 대응 전략 제언

‘거래 감소 기반 법인 고객 거래 활동성 약화 조기 탐지‘

02

EDA 및 전처리

프로젝트의 전반적 과정 소개

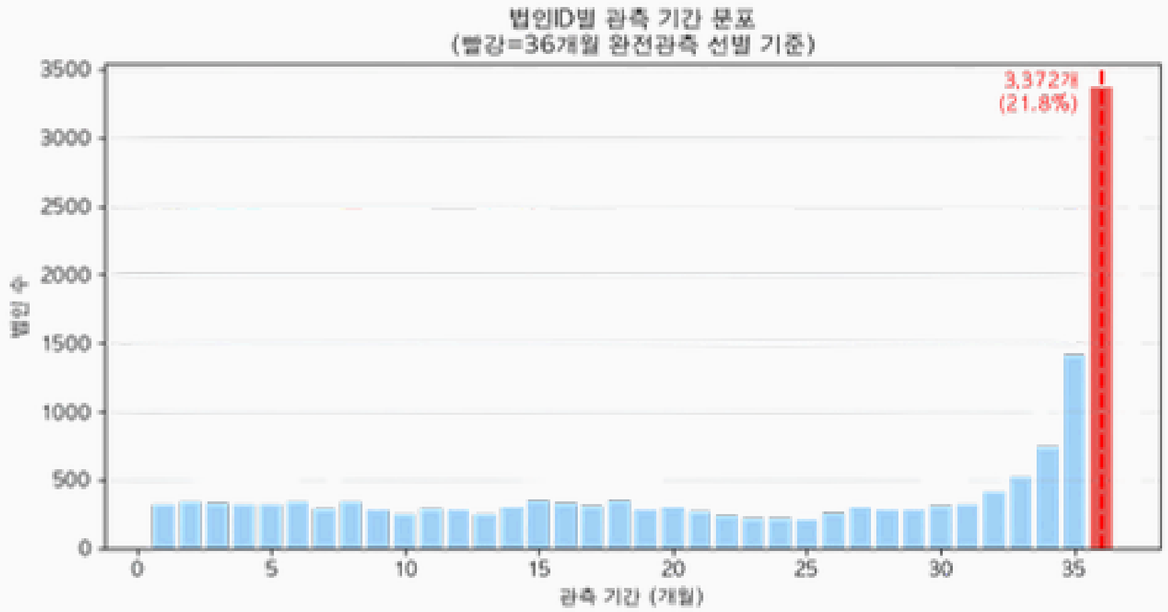
EDA 및 전처리

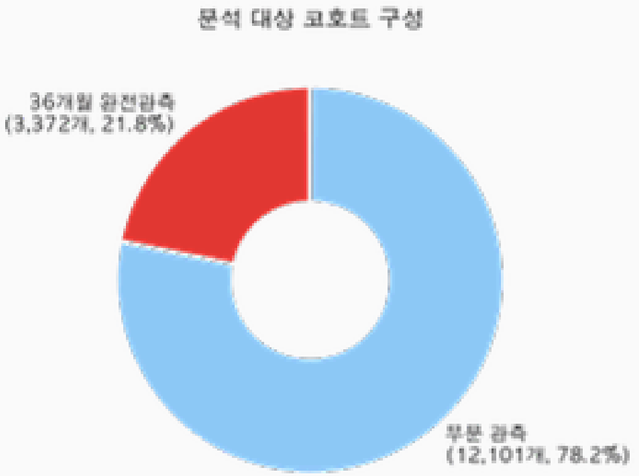
1. 데이터 기본 정보

- 파일명 : (iM뱅크) 2026 교육용 법인 익명데이터.xlsx
- 기간 : 2023년 1월 ~ 2025년 12월 (36개월)
- 대상 : 월별 iM뱅크 법인 고객
- 규모 : 365,988행 x 70열
- 결측값 : 사업장_시도 12,424건 (3.39%)
  사업장_시군구 12,424건 (3.39%)

변수 종류	변수 항목	변수 개수
범주형	**기준년월, 법인_고객등급, 전담고객여부, 업종_대분류/중분류, 사업장_시도/시군구**	**7개**
건주/좌수형	**요구불예금좌수 포함 29종** 데이터 형식 예시 : '2건 초과 5건 이하'	**29개**
수치형	**요구불예금잔액 포함 33종**	**33개**

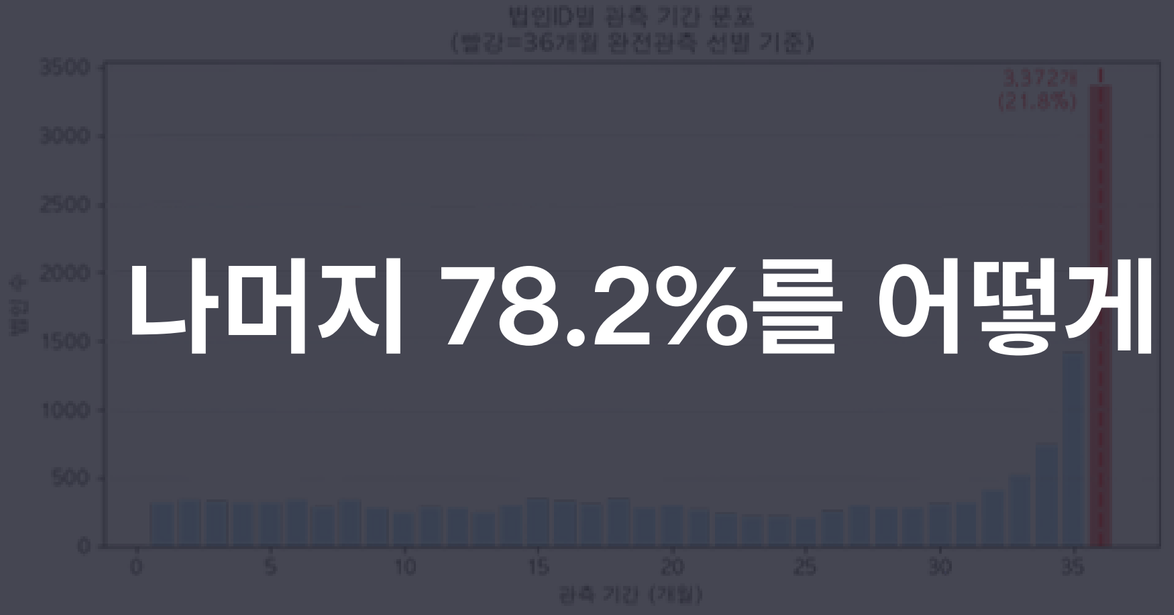
관측 개월 수별 법인 분포

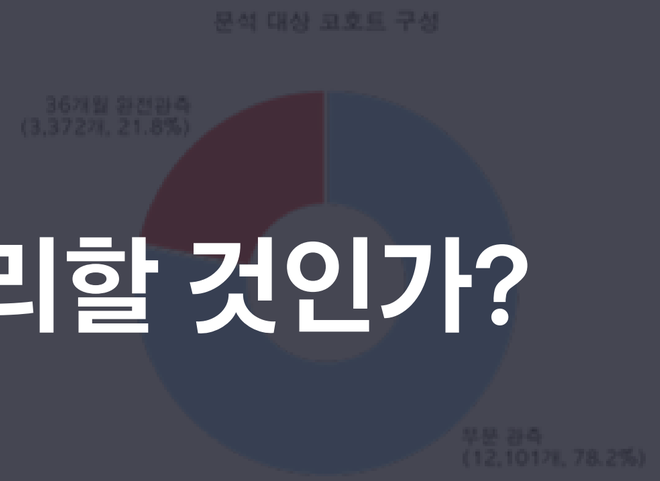




전체 15,473개 법인 중 36개월 완전관측 법인은 21.8% (3,372개)

관측 개월 수별 법인 분포





나머지 78.2%를 어떻게 처리할 것인가?

전체 15,473개 법인 중 36개월 완전관측 법인은 21.8% (3,372개)

EDA 및 전처리

2.통계적 가설검정 : 월별 거래 존재 여부 벡터화

법인ID	obs_vector
000fd5948a0ec34ce399733e5f9ce20477d0037286c99f...	11111111111111111111111111111111
0014221d70021d885c658ed03288e58a7d270934ea72df..	00000000000000011111111111111111
00649e121dc1dc289aa9b6827644ff7a8c085809fbd175...	11111111111110000000000000000000
007178b35cb54bccc9b39881f25ee566256199759fcbc4...	11110111111111111101111111111011111

관측 = 1 / 관측 X = 0

통계 검정 기준

STEP 1

GAP 검정 (이항검정)
(α = 0.01)

H_0 : 선행·후행 gap이 우연 수준 (정상 랜덤)
H_1 : 구조적 패턴 존재 (신규 유입 or 중도 종료)

기각 시 → 신규 유입 · 중도 종료 이탈 후보 분류 → 분석 제외

STEP 2

Wald-Wolfowitz Runs Test
(α = 0.05)

H_0 : 내부 누락이 랜덤 분포 (우연적 결측)
H_1 : 군집 패턴 존재 (비랜덤, 구조적 결측)

기각 불가 → 내부 누락이 랜덤임을 확인 → 보간 대상 선별

EDA 및 전처리

2. 통계적 가설검정 : 월별 거래 존재 여부 벡터화

법인ID	obs_vector	final_status
000fd5948a0ec34ce399733e5f9ce20477d0037286c99f...	11111111111111111111111111111111111	**완전 관측**
0014221d70021d885c658ed03288e58a7d270934ea72df..	00000000000000011111111111111111111	**초반 연속 누락**
00649e121dc1dc289aa9b6827644ff7a8c085809fbd175...	11111111111111000000000000000000000	**후반 연속 누락**
007178b35cb54bccc9b39881f25ee566256199759fcbc4...	11110111111111111101111111111011111	**중간 랜덤 누락**

변수 유형별 보간 규칙

1	2	3	4
발생성 금액	**연속 상태 금액**	**거래 건수**	**범주형 상태**
거래금액, 입출금금액, 카드사용금액 등	예금잔액, 여신잔액, 여신한도금액 등	창구 · ATM · 인터넷뱅킹 등 거래건수	업종, 지역, 고객등급, 전담여부, 좌수
'0' 대체	**선형 보간**	**'0건' 대체**	**마지막 관측값 유지**

(미래값 없으면 마지막값 유지)

참고: Reitzug (2025) ACM · Moritz et al. (2015) · Siddiqi (2005) Credit Risk Scorecards

EDA 및 전처리

4.최종 사용 법인

완전관측

3,372개

21.8%

36개월 연속 거래 관측
누락 이슈 없음

기본 분석 대상

+

중간랜덤누락

2,351개

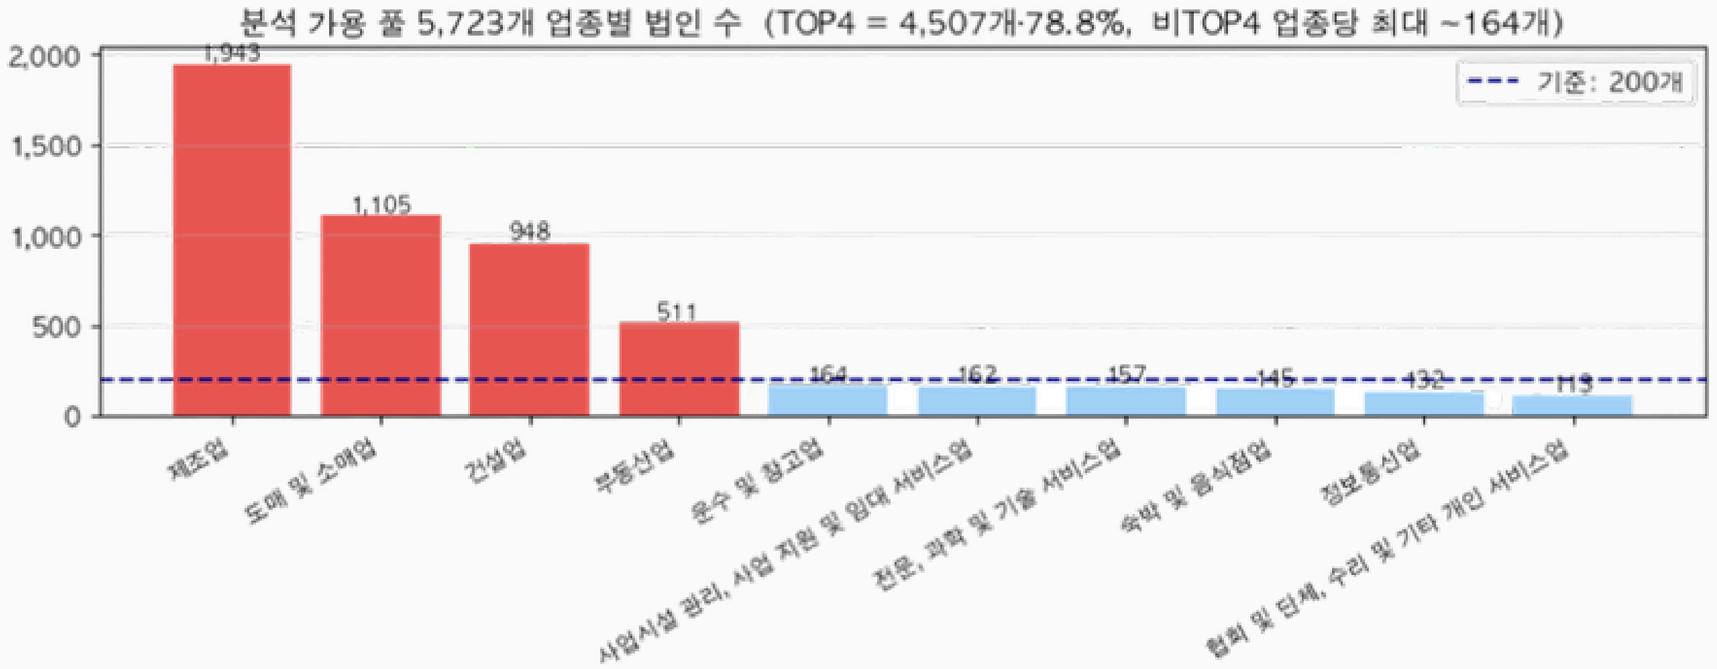
15.2%

중간 기간 랜덤 결측 발생
가설 검정 통과

선형 보간 후 사용

최종 5,723개 법인 확보

분석 대상 업종 선정



TOP4 이외의 업종은 업종당 법인 수가 최대 164개 수준으로, TOP4 대비 현저히 적어 업종별 독립 모델링이 어려움
제조업·도소매·건설·부동산 4개 업종으로 분석 범위 확정

4개 업종 집중 분석

전처리

구간 문자열 → 수치화

좌수·거래건수·개수 포함 컬럼

예시) '0건' → 0
'2건 초과 5건 이하' → 3
'5건 초과' → 6

결측치 처리 및 변환

사업장_시도 **사업장_시군구**	'Unknown' 대체
잔액변수	LOG 변환

잔여 결측 0건 → 이후 파생변수 생성 및 모델 투입 준비 완료

EDA 및 전처리

7.외부데이터

1. 외부 데이터 정리

파일명	출처	조인 키	추가 컬럼 수
버즈_전업종중분류.csv	네이버 데이터랩 API	업종_중분류 + 기준년월	1
model_sentiment_index.csv	뉴스 기사 감성분석 (자체)	업종_대분류 + 사업장_시도 + 기준년월	23
macro_indicators.csv	ECOS API + yfinance (자체 생성)	기준년월	10

사용된 외부데이터는 총 3개의 csv파일을 이용하였으며, 각 목적은 다음과 같다.

- **버즈_전업종중분류** : 업종 검색 트렌드 탐색 및 적용
- **model_sentiment_index** : 업종 및 지역 뉴스 감성지수 산출 및 적용
- **macro_indicators** : 거시 금융환경 (금리 및 환율) 반영

1. 외부 데이터 정리 - 버즈_전업종중분류

컬럼명	의미	범위
버즈	검색량 상대지수 (조회 기간 최댓값=100 기준)	0.005 ~ 100 (평균 24)

- **출처 :** 네이버 데이터랩 검색어 트렌드 API (대표 검색 키워드 매핑 후 월별 조회)
- **규모 :** 1980행 (55개 업종(중분류) × 36개월)
- **조인 키 :** 업종_중분류 + 기준년월
- **결측 :** 319건 → 전체 평균으로 대체
- **활용 :** 버즈하락 × 거래감소 등의 교호 작용으로 **업종 침체 + 이 법인의 거래 위축** 포착

EDA 및 전처리

7.외부데이터

1. 외부 데이터 정리 - model_sentiment_index(감성지수)

컬럼명	의미	범위
industry_sentiment_mean	업종 뉴스 감성 평균	-0.235 ~ 0.12 (음수=부정 우세)
industry_sentiment_median	업종 뉴스 감성 중앙값	—
industry_positive_mean	긍정 비율 평균	0 ~ 1
industry_negative_mean	부정 비율 평균	0 ~ 1
industry_neutral_mean	중립 비율 평균	0 ~ 1
industry_sentiment_std	감성 표준편차	—
industry_pos_neg_gap	긍정 – 부정 격차	—
industry_sentiment_z	표준화 감성 점수	—
industry_news_count	업종 월간 기사 수	150 ~ 250

컬럼	의미
region_sentiment_mean	지역 뉴스 감성 평균
region_sentiment_median	지역 뉴스 감성 중앙값
region_positive/negative/neutral_mean	긍/부정/중립 비율
region_sentiment_std	감성 표준편차
region_pos_neg_gap	긍정 – 부정 격차
region_sentiment_z	표준화 감성 점수
region_news_count	지역 월간 기사 수
region_low_count_flag	기사 수 부족 플래그
region_sentiment_available	지역 감성 유효 여부
region_sentiment_filled	결측 보정 후 감성값

컬럼	의미
mixed_sentiment_index	업종 + 지역 혼합 감성 지수
region_unknown_flag	사업장_시도 = 'Unknown' 여부 (1= 불명)

각 표 별 의미

1. **업종 감성**
2. **지역 감성**
3. **혼합 감성**

- **출처 :** 뉴스 기사 크롤링으로 수집 후, 자체 감성분석 파이프라인 (KoBERT)
- **규모 :** 720행 (4개 업종(대분류) × 5개 지역 × 36개월
- **조인 키 :** 업종_대분류 + 사업장_시도 + 기준년월
- **커버 업종 :** 제조업, 도매 및 소매업, 건설업, 부동산업
- **커버 지역 :** 대구 / 경북 / 수도권 / 부울경 / 기타 (5개 그룹)
- **결측** : 업종감성 → 중앙값 대체 / 지역 Unknown → 업종 감성값 대체.

EDA 및 전처리

7.외부데이터

1. 외부 데이터 정리 - macro_indicators

컬럼	의미	출처	범위(실측)
기준금리	한국은행 기준금리 (%)	ECOS 722Y001	3.5 → 2.5 (인하 사이클)
USD_KRW	원/달러 월평균 환율	yfinance USDKRW=X	1,231 ~ 1,469
CD금리	CD(91일) 금리 (%)	ECOS 721Y001	2.62 ~ 4.49
국고채3년	국고채 3년물 수익률 (%)	ECOS 721Y001	2.33 ~ 4.03
기준금리_전월대비	기준금리 월간 변화	파생	-0.25 ~ 0
USD_KRW_전월대비	환율 월간 변화	파생	-59.7 ~ +86.8
금리_3개월MA	기준금리 3개월 이동평균	파생	—
환율_3개월MA	USD_KRW 3개월 이동평균	파생	—
금리_변동성	기준금리 3개월 표준편차	파생	0 ~ 0.25
CD_국고차이	CD금리 − 국고채3년 (단·장기 스프레드)	분석 중 코드 내 파생	—

- **출처 :** 한국은행 ECOS API (금리) + yfinance (환율) — 본 프로젝트에서 직접 생성
- **규모 :** 36행 = 36개월 (업종·지역 무관, 모든 법인 공통)
- **조인 키 :** 기준년월

EDA 및 전처리

8.파생 변수

2. 파생 변수 정리

변수	정의
총예금잔액	요구불 + 거치식 + 적립식 예금잔액
총여신잔액	운전자금대출 + 시설자금대출 잔액
총투자잔액	수익증권 + 신탁 + 퇴직연금 잔액
비대면거래금액	인터넷뱅킹 + 스마트뱅킹 + 폰뱅킹 + ATM
총거래금액	창구 + 인터넷뱅킹 + 스마트뱅킹 + 폰뱅킹
총카드사용액	신용카드 + 체크카드 사용금액
총외환실적	외환 수출실적 + 수입실적

변수	정의
비대면_비중	비대면거래금액 / 총거래금액
카드_비중	총카드사용액 / 총거래금액
자동이체_비중	자동이체금액 / 총거래금액
외환_비중	총외환실적 / 총거래금액
창구_비중	창구거래금액 / 총거래금액
디지털_전환율	비대면거래금액 / (창구 + 비대면거래금액)
신용_체크_비율	신용카드사용금액 / 체크카드사용금액

변수	정의
외환거래여부	총외환실적 > 0 → 1
카드사용여부	총카드사용액 > 0 → 1
디지털거래여부	비대면거래금액 > 0 → 1

각 표 별 의미

1. **합산 변수**
2. **비율 변수**
3. **플래그 변수**

- **기준 :** 분석 중 보간 포함한 확장 모델을 기준으로 파생 변수 생성
- **생성 원리 :** 기본 변수들을 이용하며, 시계열 연산은 법인ID 별 기준년월 정렬 후 연산. (EPS = 1e-9)
- **누수 방지 원칙 :** 타겟은 거래 건수 기반이므로, 파생변수는 전부 거래금액·잔액 기반으로만 생성.
  거래건수·M_freq·freq_CV 계열은 피처에서 완전 제외.

EDA 및 전처리

8.파생 변수

2. 파생 변수 정리 - 시계열 파생

- **대상 컬럼 : 22개 컬럼**
  - **행동/거래(14개) :** 총거래금액, 비대면거래금액, 창구거래금액, 자동이체금액, 총카드사용액, 총외환실적, 인터넷뱅킹거래금액, 스마트뱅킹거래금액, 신용카드사용금액, 체크카드사용금액, 비대면_비중, 디지털_전환율, 카드_비중, 자동이체_비중
  - **잔액 (8개) :** 요구불예금잔액, 거치식예금잔액, 적립식예금잔액, 총예금잔액, 여신_운전자금대출잔액, 여신_시설자금대출잔액, 총여신잔액, 여신한도금액

- **example)**
  총거래금액_pct3(3개월 거래금액 변화율),
  총예금잔액_CV6(예금 변동성),
  총여신잔액_peak_ratio(대출 고점 대비 현재 수준)

- **감소 여부 :** 대상 컬럼 13개
  - **잔액 (8개) :** 상단과 동일
  - **행동/거래(5개) :** 총거래금액, 비대면거래금액, 자동이체금액, 총카드사용액, 총외환실적

접미사	의미
_lag1 / _lag3 / _lag6	1 / 3 / 6개월 전 값
_diff1 / _diff3	1 / 3개월 전 대비 증감(절대량)
_pct1 / _pct3	1 / 3개월 전 대비 변화율
_ma3 / _ma6	3 / 6개월 이동평균
_std3	3개월 표준편차(변동폭)
_CV6	6개월 변동계수 = 표준편차 / 평균
_max6	6개월 최댓값
_peak_ratio	현재값 / 6개월 최댓값 (고점 대비 현재 수준)
_accel	2차 차분(변화의 가속도) = diff1 − 직전 diff1

변수	정의
감소 여부 플래그	전월 대비 감소 여부 (감소 시 1 / 외 0)

2. 파생 변수 정리

변수	정의
행동복합감소점수	KEY_BEHAV 5개 감소여부의 합 (0~5, 클수록 다수 행동 동시 위축)

변수	정의
체크카드_비율	체크카드 / (신용카드 + 체크카드) — 유동성 악화 시 ↑
체크카드비율_증가	체크카드_비율이 전월 대비 증가 → 1

변수	정의
수출_비중	수출실적 / (수출 + 수입)
수출입_불균형	(수출 − 수입) / (수출 + 수입)
수출_감소여부	수출실적 전월 대비 감소 → 1

변수	정의
채널_HHI집중도	6개 채널 거래비중의 제곱합(허핀달지수). 높을수록 특정 채널 쏠림
채널_엔트로피	채널 비중의 엔트로피. 낮을수록 집중
활성채널수	거래금액 > 0 인 채널 수
채널집중도_증가	채널_HHI집중도가 전월 대비 증가 → 1

변수	정의
총거래금액_연속하락기간	총거래금액이 연속으로 감소한 개월 수
비대면거래금액_연속하락기간	동일 (비대면거래)
총카드사용액_연속하락기간	동일 (카드사용)

각 표 별 의미

1. **복합 지표**
2. **카드 사용 패턴**
3. **수출입 패턴**
4. **거래채널 다양성**
5. **연속하락 기간**

EDA 및 전처리

8.파생 변수

2. 파생 변수 정리 - 외부 데이터 기반

변수	출처	의미
BSI_업황	ECOS	기업경기실사지수 — 업황 (기준선 100)
BSI_자금사정	ECOS	기업경기실사지수 — 자금사정 (기준선 100)
뉴스심리	ECOS	뉴스심리지수 (기준선 100)
ESI	ECOS	경제심리지수 (기준선 100)

변수	의미
버즈	네이버 DataLab 검색량 상대지수 (0~100)
버즈_전월대비	버즈 지수 전월 대비 증감
버즈_3개월변화	3개월 전 대비 증감
버즈_pct3	3개월 전 대비 변화율

변수	의미
기준금리	한국은행 기준금리 (%)
USD_KRW	원/달러 월평균 환율
CD금리	CD(91일) 금리 (%)
국고채3년	국고채 3년물 수익률 (%)
기준금리_전월대비	금리 월간 변화
USD_KRW_전월대비	환율 월간 변화
금리_3개월MA	기준금리 3개월 이동평균
환율_3개월MA	USD_KRW 3개월 이동평균
금리_변동성	기준금리 3개월 표준편차
CD_국고차이	CD금리 − 국고채3년 (단기·장기 스프레드)

각 표 별 의미

1. **경기 심리 지표**
(업종_대분류 × 기준년월 조인)
2. **버즈 시계열 파생**
(업종_중분류 × 기준년월 조인)
3. **거시 금융 환경**
(기준년월 조인 - 전 법인 공통)

2. 파생 변수 정리 - 외부 데이터 기반

변수	의미
industry_sentiment_mean	업종 뉴스 감성 평균 (음수=부정 우세)
region_sentiment_mean	지역 뉴스 감성 평균

변수	포착 신호
버즈하락_X_거래감소	업종 관심 하락 + 이 법인만 거래 감소
버즈하락_X_복합감소	업종 관심 하락 + 복합 위축
버즈추세하락_X_복합감소	3개월 검색 추세 하락 + 복합 위축
버즈저관심_X_거래감소	저관심 업종 + 거래 감소
버즈급감_X_거래감소	검색 3개월 20%+ 급감 + 거래 감소
버즈급감_X_외환기업	검색 급감 + 외환거래 기업

변수	포착 신호
금리상승_X_거래감소	금리 오르는 달 + 거래 감소 = 자금 압박
금리상승_X_복합감소	금리 상승 + 다수 행동 동시 위축
금리인하_BUT_거래감소	금리 내리는데도 거래 감소 = 구조적 감소(강한 신호)
고금리_X_복합감소	절대 고금리 시기 + 복합 위축
환율급등_X_외환기업	환율 급등 + 외환거래 기업 = 환리스크 노출
환율급등_X_거래감소	환율 급등 + 거래 위축
고환율_X_복합감소	고환율 시기 + 복합 위축
복합스트레스_X_거래감소	고금리 + 고환율 동시 + 거래 감소 (삼중 압박)
복합스트레스_X_복합감소	고금리 + 고환율 + 다수 행동 위축

각 표 별 의미

1. **뉴스 감성지수 (업종_대분류 × 사업장_시도 × 기준년월 조인)**
2. **버즈 × 행동 교호작용 지표**
3. **매크로 × 행동 교호작용 지표**

EDA 및 전처리

9. 실험 파이프 라인

	피처: 원본 변수만	피처: 파생 + 외부데이터
완전 관측 (2,651)	**베이스 라인** • 원본 변수 only	**피처 확장** • 파생 + 외부데이터
보간 포함 (4,507)	**보간 효과 검증** • 원본 변수 only	**최종 완전 모델** • 파생 + 외부데이터

원천 데이터 → 결측/보간 → Y 생성 → Y_next1 shift → 누수 제거 → Time split

03

베이스 모델

변수 선정 및 적합 모델 선정 목적

베이스 모델

1. y값 선정

y값 선정_1번

과거 3개월 대비 최근 3개월의 잔액 증감률(%)

법인의 주거래 여부를 가장 잘 나타내는 핵심 변수로 설정
→ 요구불예금잔액, 여신_운전자금대출잔액

t : 기준년월
계산된 ΔM 값이 설정한 임계치(예: -50%)보다 작으면(즉, 50% 초과 감소)
해당 월(t)의 타겟 변수를 Y=1 로 라벨링

$$\Delta M = \frac{(t\text{월} + t_{-1}\text{월} + t_{-2}\text{월의 잔액}) - (t_{-3}\text{월} + t_{-4}\text{월} + t_{-5}\text{월의 잔액})}{t_{-3}\text{월} + t_{-4}\text{월} + t_{-5}\text{월의 잔액}}$$

문제점

1. y값과 프로젝트 방향성

: 거래활동성 약화 탐지를 예금잔액과 대출잔액의 증감률로 보기에는 문제가 있음

2. 예금잔액과 대출잔액의 중요도

: 학습을 진행하는데, 예금잔액과 대출잔액을 제외하기엔 큰 부분을 차지

3 성능 평가

```
accuracy: 0.821
precision: 0.1913
recall: 0.7425
f1: 0.3042
pr_auc: 0.256
roc_auc: 0.8677
```

베이스 모델

1. y값 선정

y값 선정_2번

조건 1 (Frequency)

: 월별 '총 거래 건수'의 이동 구간 변화율 M이 임계값 이하로 하락

조건 2 (Regularity)

: 총 거래 건수의 변동계수(CV)가 평균 초과

두 조건 중 하나라도 깨지면 부분 이탈로 판단
충성 고객 부분 이탈 관련 논문을 바탕으로 설정
검증셋에서 F1을 최대화하는 임계값을 선정하는 방식
또한, 같은 저자의 논문을 바탕으로 설정

개선점

1. y값과 프로젝트 방향성

:총 거래 건수를 보기에, 실질적인 이용 상황을 파악 가능

2. 선정 방식의 타당성

:당월 y값이 아니라, 다음월 y값을 활용해 1개월 선행 타겟을 구성

```
46  # ── 1개월 SHIFT: X_t -> y_next1 = y_current_{t+1} ──
47  df['y_next1'] = df.groupby('법인ID')['y_current'].shift(-1)
48  df['target_기준년월'] = df.groupby('법인ID')['기준년월'].shift(-1)
```

1. Frequency of purchases is above average.
2. Ratio of the standard deviation of the interpurchase time to the mean interpurchase time is below average.

this time over a period of observation *after* the period used to determine behavioural loyalty (i.e., after point 'P' in Fig. 1). So, if one of the above mentioned conditions (1) or (2) is not fulfilled, we

classify a customer as partially defective (as the dependent variable) because he deviates from his established transaction pattern.

In practice, decision rules that maximize F1 are often set empirically, rather than analytically. That is, given a set of validation examples with predicted scores and true labels, rules for mapping scores to labels are selected that maximize F1 on the validation set. In such situations, the optimal threshold can be subject to a winner's curse [2] where a sub-optimal threshold is chosen because of sampling effects or limited training data. As a result, the future performance of a classifier using this threshold is worse than the anticipated performance. We show that threshold optimization for F1 is particularly susceptible to this phenomenon.

베이스 모델

2. train / valid / test set 정의

TRAIN / VALID / TEST

구분	X 기준년월	Target 기준년월	역할	사용처
TRAIN	202301 ~ 202505	202302 ~ 202506	모델 학습	통합모델, 업종별 모델 학습
VALID	202506~202508	202507~202509	튜닝 / 임계값 선택	threshold 조정 , 모델 선택
TEST	202509~202511	202510~202512	최종 성능 평가	ROC-AUC, PR-AUC, F1등 최종 검증
Y_next1	현재월 X	다음월 y	조기탐지 구조	현재월 정보로 다음월 거래 활동성 약화를 예측

베이스 모델

3.모델링

전체 데이터(36개월)_거래건수 제외_BASE LINE

누수 차단

```
3  # 타깃의 직접 재료(거래건수 계열)를 피처에서 전량 제거 → 누수 차단
4  COUNT_LEAK_KW = ['거래건수','총거래건수','M_freq','freq_CV','freq','Frequency']
5  count_leak_cols = [c for c in dfx.columns if any(k in c for k in COUNT_LEAK_KW)]
```

```
# 미래 누수 방지 – 무작위 분할이 아닌 '시간순' 분할
test_months_p2 = [202510, 202511, 202512] # 최근 3개월 = test(미래)
5  df_train = dfx[_tr & ~dfx['기준년월'].isin(_vm)].copy() # 과거
6  df_valid = dfx[_tr &  dfx['기준년월'].isin(_vm)].copy() # threshold 튜닝용
7  df_test  = dfx[dfx['기준년월'].isin(test_months_p2)].copy()
```

TRAIN / VALID / TEST 데이터 셋업

베이스 모델

3. 모델링

전체 데이터(36개월)_거래건수 제외_BASE LINE

LIGHTGBM 사용

```
7   from lightgbm import LGBMClassifier
```

기본 파라미터

```
10      return Pipeline([('prep', pre), ('model', LGBMClassifier(**params, random_state=42, n_jobs=-1, verbose=-1))])
11
27  LGBM_PARAMS = dict(n_estimators=500, learning_rate=0.05, max_depth=6, num_leaves=31)
```

```
1   TARGET_INDS = ['제조업', '도매 및 소매업', '건설업', '부동산업']
2   IND_MODELS = {}; IND_RESULTS = []
3   for ind in TARGET_INDS:
```

제조업, 도매 및 소매업, 건설업, 부동산업 사용

업종 단위로 개별 모델 반복 학습

베이스 모델

3.모델링

전체 데이터(36개월)_거래건수 제외_BASE LINE

업종(d)에 따라 해당 업종 전용 모델로 탐지를 분기(routing)하는 함수

```
1   def routed_predict(d):
```

```
16  # 업종 top4로 제한 _ 업종별 모델 + 앙상블 대상
17  TOP4_INDS = ['제조업', '도매 및 소매업', '건설업', '부동산업']
18  dfx = df_model[df_model['업종_대분류'].isin(TOP4_INDS)].sort_values(['법인ID','기준년월']).reset_index(drop=True).copy()
```

```
15  te_blend = 0.5*te_routed + 0.5*te_int
```

블렌딩 사용

평가 /
임계값을 전략별로 별도 튜닝

```
24  R_routed = eval_all(df_test['y'], te_routed, thr_r)
25  R_blend  = eval_all(df_test['y'], te_blend , thr_b)
```

베이스 모델

3. 모델링

모델링 실험 구조

실험	데이터	변수 구조	실험 목적
BASE LINE	36개월 완전관측	기본 금융 변수, 거래건수 제거	BASE LINE
BASE LINE + 파생 + 외부 데이터	36개월 완전관측	기본 금융 변수 + 파생 + 외부 데이터	변수 확장 효과 확인
BASE LINE	36개월 완전관측 + 중간랜덤누락 보간	기본 금융 변수, 거래건수 제거	보간 단독 효과 확인
BASE LINE + 파생 + 외부 데이터	36개월 완전관측 + 중간랜덤누락 보간	기본 금융 변수 + 파생 + 외부 데이터	최종 확장 모델

X변수들끼리 corr기반으로 변수를 제거해가며 실험 진행

베이스 모델

3. 모델링

전체 데이터(36개월)_BASE LINE vs 파생 + 외부 데이터

36개월_BASE LINE

	모델	ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy	thr
0	업종라우팅	0.8603	0.8151	0.7770	0.8587	0.7095	0.7763	0.375
1	통합	0.8577	0.8086	0.7751	0.8342	0.7238	0.7803	0.473
2	블렌딩(0.5:0.5)	0.8644	0.8197	0.7792	0.8288	0.7353	0.7869	0.471

36개월_파생 + 외부 데이터

	모델	ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy	thr
0	업종라우팅	0.8744	0.8373	0.7850	0.8458	0.7323	0.7897	0.384
1	통합	0.8723	0.8329	0.7738	0.8047	0.7452	0.7865	0.508
2	블렌딩(0.5:0.5)	0.8782	0.8424	0.7865	0.8283	0.7487	0.7959	0.459

베이스 모델

3. 모델링

전체 데이터(보간 + 36개월)_BASE LINE vs 파생 + 외부 데이터

보간 + 36개월_BASE LINE

	모델	ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy	thr
0	업종라우팅	0.8363	0.7767	0.7204	0.7905	0.6617	0.7502	0.455
1	통합	0.8320	0.7703	0.7185	0.8199	0.6394	0.7384	0.442
2	블렌딩(0.5:0.5)	0.8404	0.7828	0.7234	0.8275	0.6426	0.7424	0.423

보간 + 36개월파생 + 외부 데이터

	모델	ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy	thr
0	업종라우팅	0.8956	0.8628	0.7729	0.8010	0.7467	0.8100	0.497
1	통합	0.8957	0.8634	0.7695	0.8045	0.7374	0.8054	0.523
2	블렌딩(0.5:0.5)	0.8995	0.8684	0.7793	0.8177	0.7443	0.8130	0.498

04

업종별 모델

베이스 기반 세부적인 모델 제시

업종별 모델

1. 업종별 모델 선정 이유

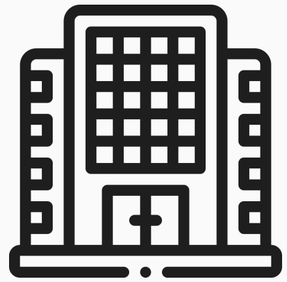


대규모 수주로 인해,
운전자금
대출하겠습니다.

제조업 중 자동차 공장의 경우



이번에 공사 대금이
다 회수되어서,
지금은 대출이
필요하지 않네요.



건설업 중 공사업체의 경우

- 업종별, 고객 거래 활동성 약화의 메커니즘이 다름.
- 금융 거래의 형태가 동일해도, 업종마다 의미가 다를 수 있음.

업종별 모델

2. 업종별 모델 결과 - 건설업

1. 건설업 거래 활동성 약화 탐지 성능 비교

- 기본변수만 사용한 모델

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.8439	0.7959	0.78	0.8203	0.7435	0.777

- 파생변수 및 외부변수 추가 사용 모델

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.869	0.8346	0.7869	0.8345	0.7444	0.7822

VS

- 중간 누락 보간 후 기본변수

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.8229	0.7458	0.7129	0.8205	0.6302	0.7307

- 중간 누락 보간 후 파생 및 외부변수
  (사용변수 : 249개)

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.8876	0.8493	0.7609	0.8266	0.7049	0.7883

업종별 모델

2. 업종별 모델 결과 - 건설업

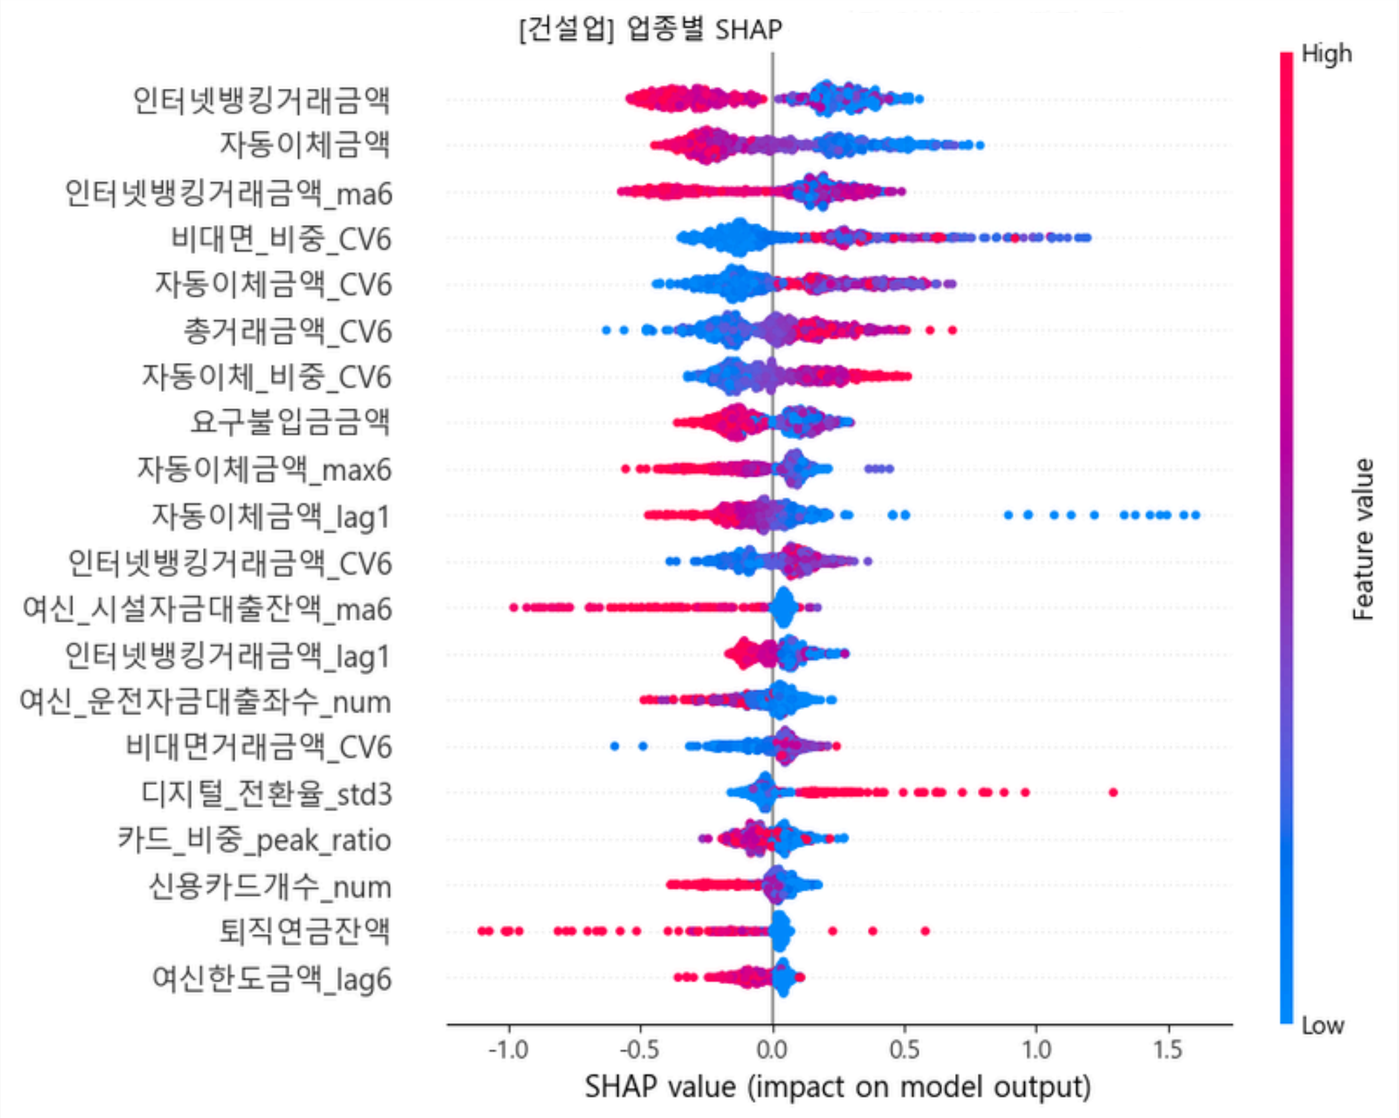
2. 채택된 모델의 SHAP value

상위 변수

1. 인터넷뱅킹거래금액 : 감소
2. 자동이체금액 : 감소
3. 인터넷뱅킹거래금액 ma6 : 감소

감소 변수

1. 인터넷뱅킹거래금액
2. 자동이체금액
3. 인터넷뱅킹거래금액 ma6



업종별 모델

3. 업종별 모델 결과 - 도매 및 소매업

1. 도매 및 소매업 거래 활동성 약화 탐지 성능 비교

- 기본변수만 사용한 모델

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.8965	0.8228	0.7273	0.6929	0.7652	0.813

- 파생변수 및 외부변수 추가 사용 모델

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.9061	0.84	0.7867	0.8386	0.7409	0.8364

VS

- 중간 누락 보간 후 기본변수

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.8616	0.7739	0.7058	0.7408	0.6739	0.7822

- 중간 누락 보간 후 파생 및 외부변수
  (사용변수 : 251개)

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.9329	0.8922	0.7962	0.7938	0.7986	0.8567

업종별 모델

3.업종별 모델 결과 - 도매 및 소매업

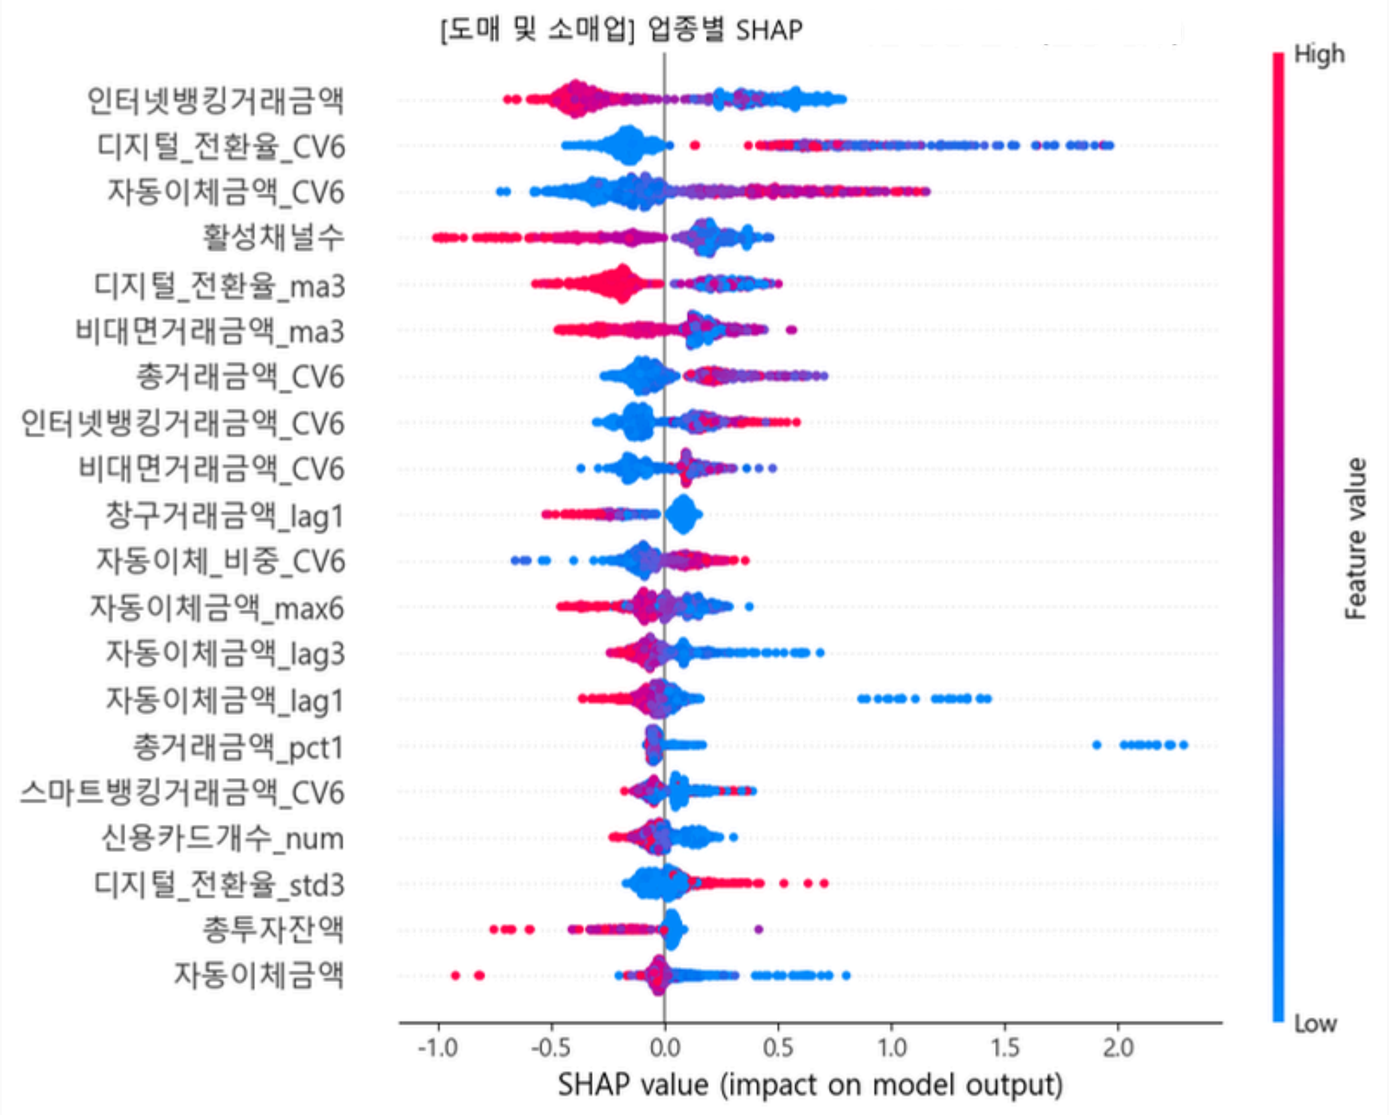
2. 채택된 모델의 SHAP value

상위 변수

1. 인터넷뱅킹거래금액 : 감소
2. 디지털전환율 CV6 : 증가
3. 자동이체금액 CV6 : 증가

감소 변수

1. 인터넷뱅킹거래금액
2. 활성채널 수
3. 비대면거래금액 ma3



1. 부동산업 거래 활동성 약화 탐지 성능 비교

- 기본변수만 사용한 모델

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.7934	0.8647	0.8287	0.94	0.741	0.7472

- 파생변수 및 외부변수 추가 사용 모델

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.812	0.8868	0.8418	0.9429	0.7604	0.7695

VS

- 중간 누락 보간 후 기본변수

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.7777	0.7899	0.7449	0.8435	0.667	0.6967

- 중간 누락 보간 후 파생 및 외부변수
(사용변수 : 273개)

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.8403	0.8575	0.7834	0.8696	0.7128	0.7476

업종별 모델

4. 업종별 모델 결과 - 부동산업

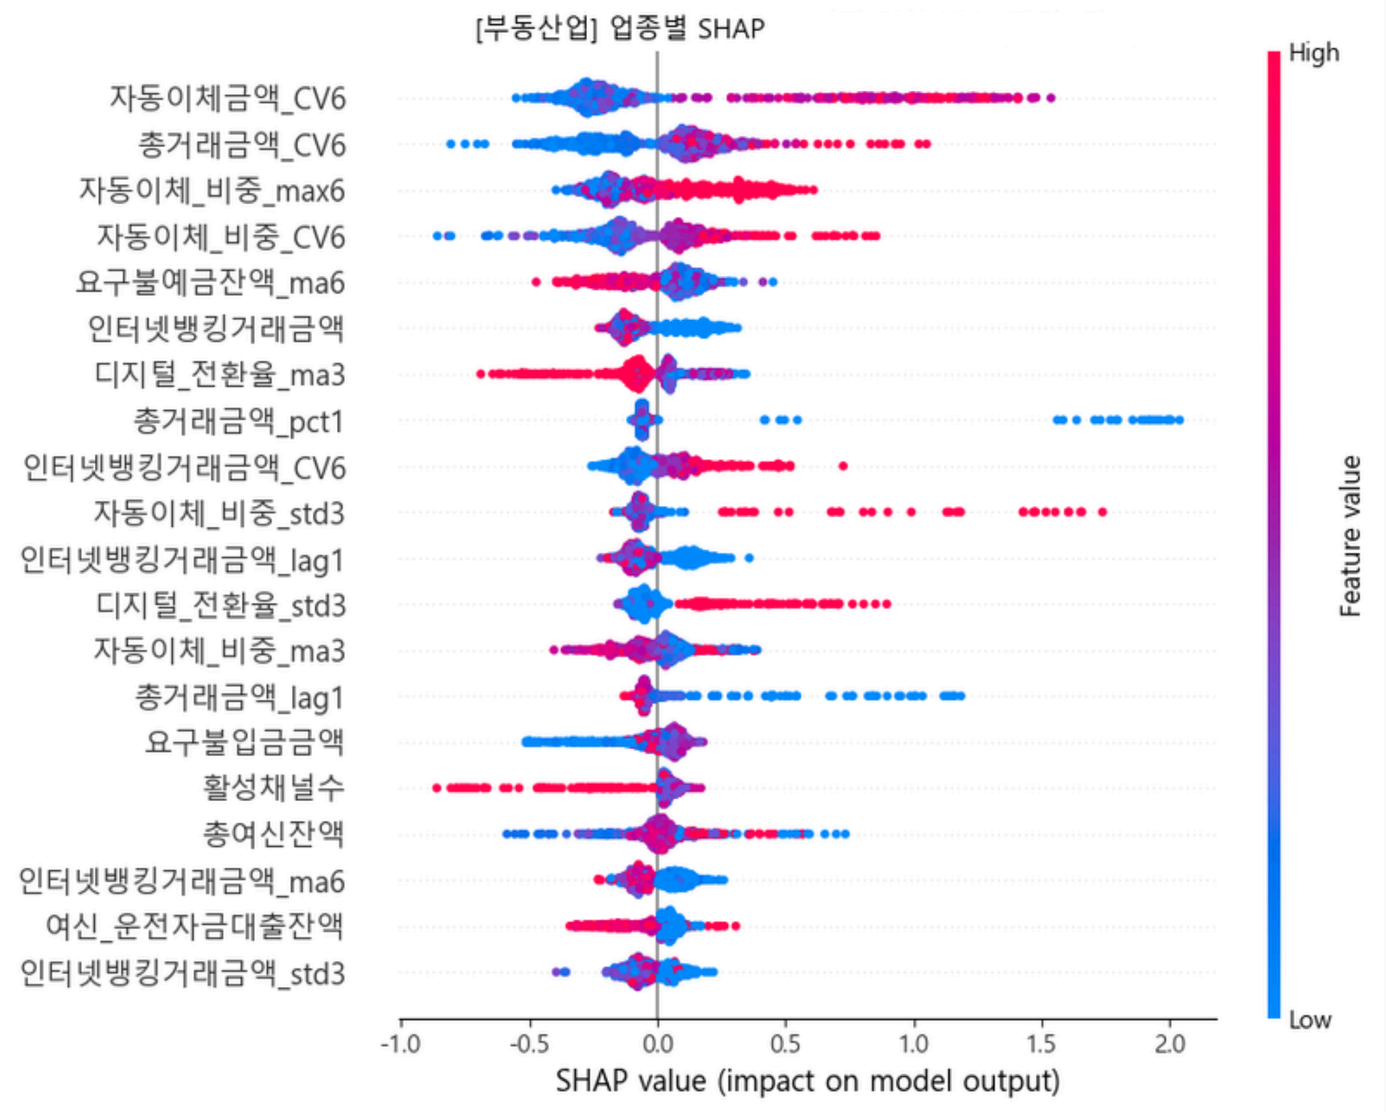
2. 채택된 모델의 SHAP value

상위 변수

1. 자동이체금액 CV6 : 증가
2. 총거래금액 CV6 : 증가
3. 자동이체비중 max6 : 증가

감소 변수

1. 요구불예금잔액 ma6
2. 인터넷뱅킹거래금액
3. 디지털전환율 ma3



업종별 모델

5. 업종별 모델 결과 - 제조업

1. 제조업 거래 활동성 약화 탐지 성능 비교

- 기본변수만 사용한 모델

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.8509	0.8066	0.7717	0.8621	0.6984	0.7699

- 파생변수 및 외부변수 추가 사용 모델

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.8603	0.8173	0.7706	0.857	0.7001	0.7699

VS

- 중간 누락 보간 후 기본변수

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.8183	0.7519	0.6933	0.7265	0.6631	0.7437

- 중간 누락 보간 후 파생 및 외부변수
  (사용변수 : 263개)

ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
0.9225	0.8993	0.7966	0.7832	0.8104	0.8405

업종별 모델

5. 업종별 모델 결과 - 제조업

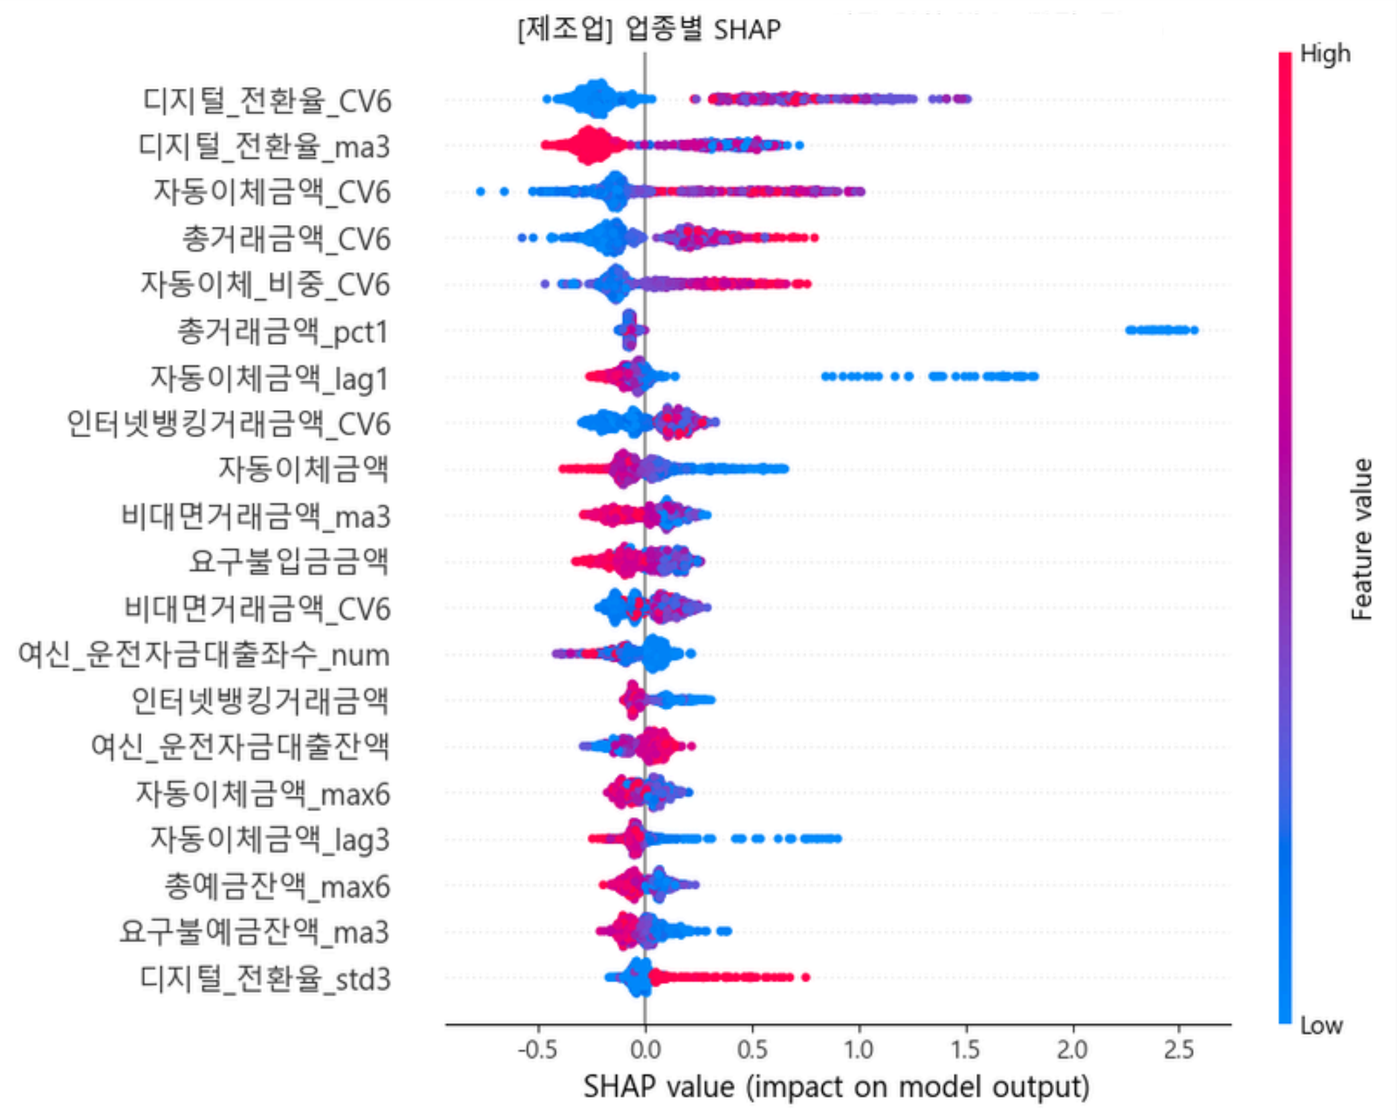
2. 채택된 모델의 SHAP value

상위 변수

1. 디지털전환율 CV6 : 증가
2. 디지털전환율 ma3 : 감소
3. 자동이체금액 CV6 : 증가

감소 변수

1. 디지털전환율 ma3
2. 자동이체금액 lag1
3. 자동이체금액



업종별 모델

6. 업종별 모델 결과 - 업종별 주요변수

• 각 채택 모델 SHAP 기반 업종별 주요 변수

- 건설업

  주요 변수: 인터넷뱅킹거래금액, 자동이체금액, 비대면 비중 CV6

- 도매 및 소매업

  주요 변수: 인터넷뱅킹거래금액, 자동이체금액CV6, 디지털전환율 CV6

- 부동산업

  주요 변수: 자동이체금액 CV6, 총거래금액 CV6 요구불예금잔액 ma6

- 제조업

  주요 변수: 디지털전환율 CV6, 디지털전환율 ma3, 자동이체금액CV6

업종별 모델

7.업종별 모델 결과 - 통합 모델

1. 통합 모델의 성능 지표

모델	ROC_AUC	PR_AUC	F1	Recall	Precision	Accuracy
업종라우팅	0.9107	0.8815	0.7901	0.8168	0.7652	0.8249
통합	0.9104	0.8826	0.7861	0.8223	0.753	0.8194
블렌딩(0.5:0.5)	0.9145	0.8879	0.7917	0.8126	0.7718	0.8274

- 목적에 부합한 모든 변수를 사용한 모델인 **보간 후 외부 변수 포함한 모델**들을 앙상블한 **최종 모델**

업종별 모델

7.업종별 모델 결과 - 통합 모델

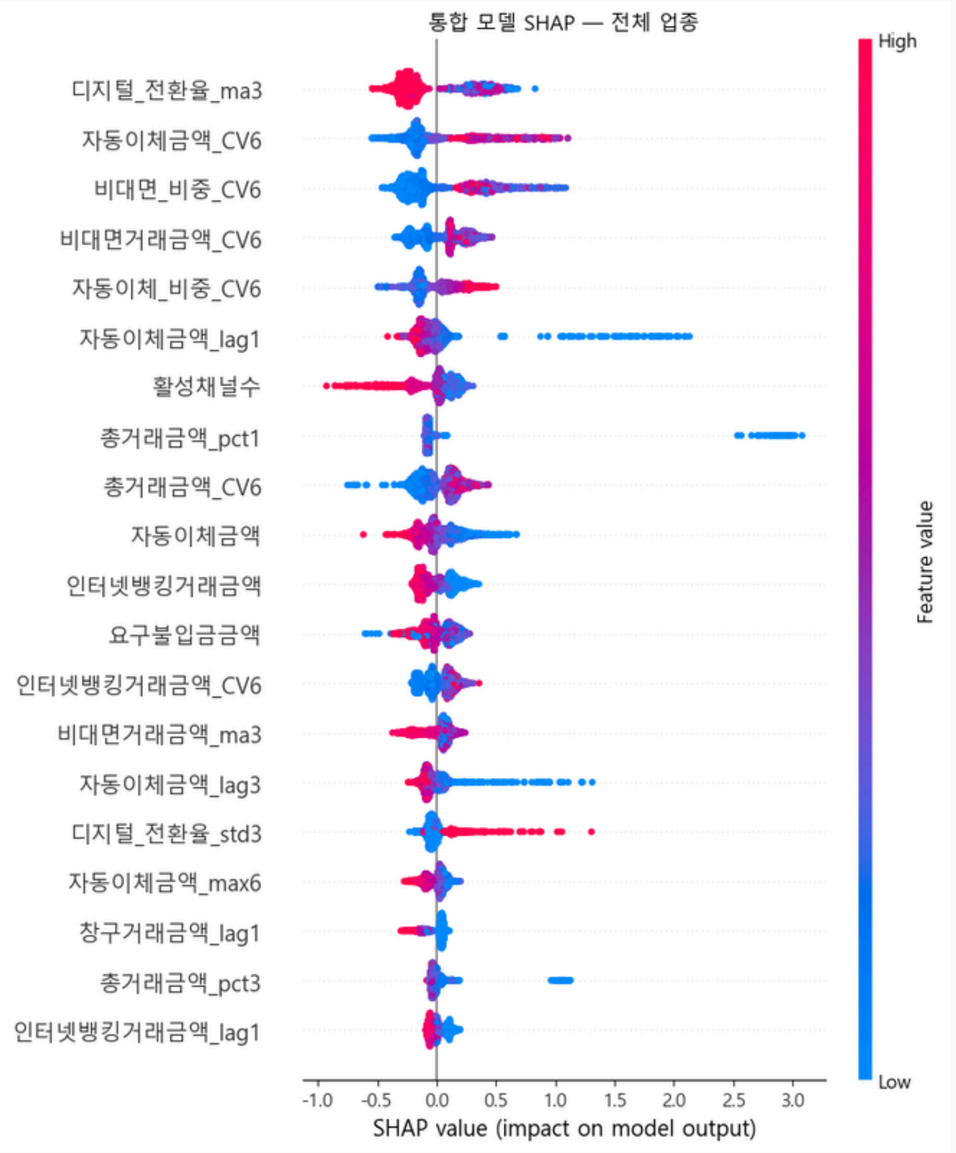
2. 통합 모델의 SHAP value

상위 변수

1. 디지털전환율 ma3: 감소
2. 자동이체금액 CV6: 증가
3. 비대면비중 CV6: 증가

감소 변수

1. 디지털전환율 ma3
2. 자동이체금액 lag1
3. 활성채널 수



05

페르소나 분석

최종 모델 기반 페르소나 분석

페르소나 분석

1. 왜 페르소나 분석을 했는가

조기탐지를 넘어, “왜 위험한가”를 설명하기 위해서

STEP1	STEP2	STEP3	STEP4
블렌딩 모델의 Y 탐지	통합모델 SHAP 법인 ID별 평균 벡터	KMeans 설명공간 군집화	고객 유형화 및 관리 방식 차별화

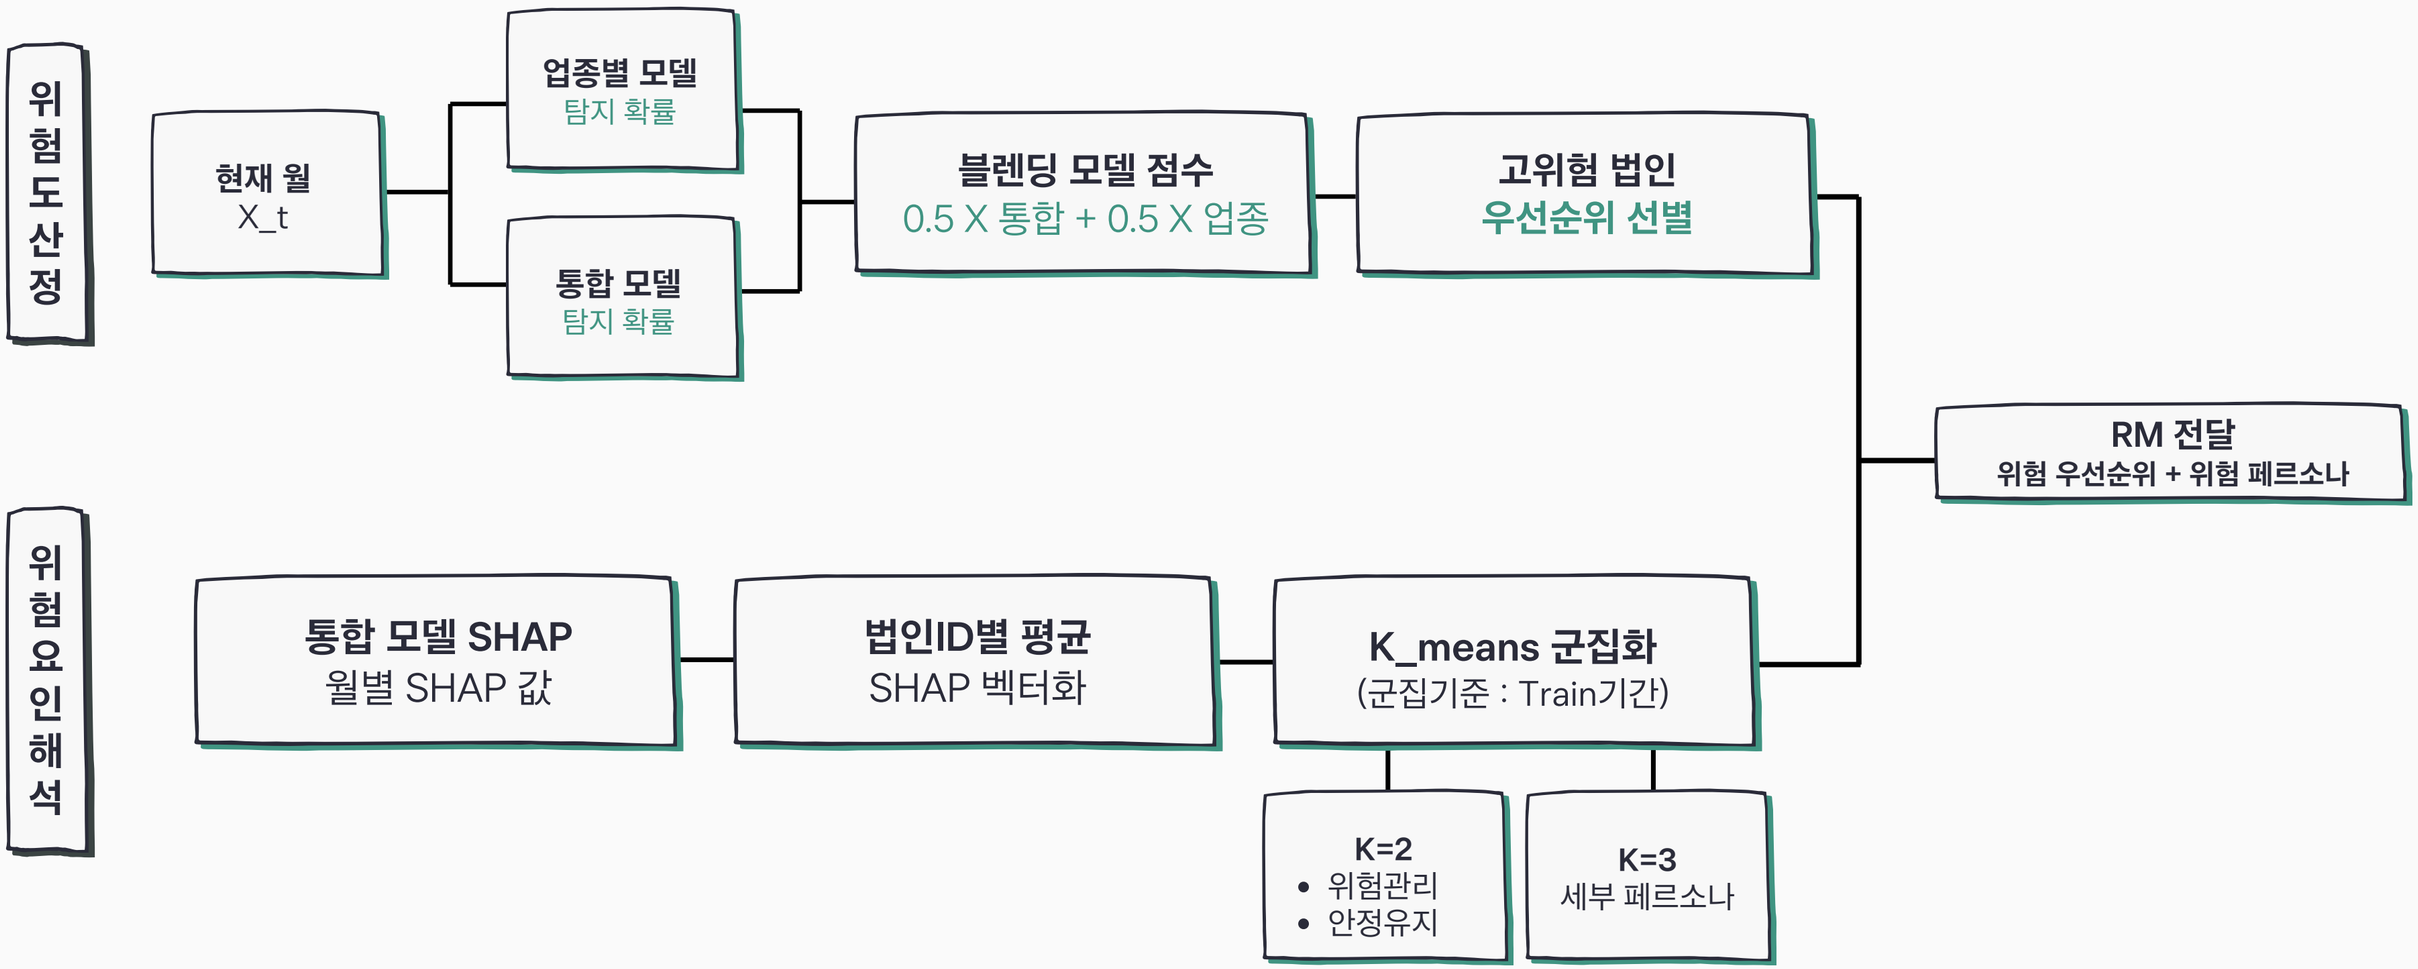
- 모델은 **활동성 감소**를 조기탐지
- 은행은 왜 위험한지가 필요
- 그래서 SHAP 기반으로 위험 고객의 패턴을 페르소나화

위험도 산정 (Y) : **블렌딩 모델**

페르소나 해석: **통합 모델의 SHAP 기준**

페르소나 분석

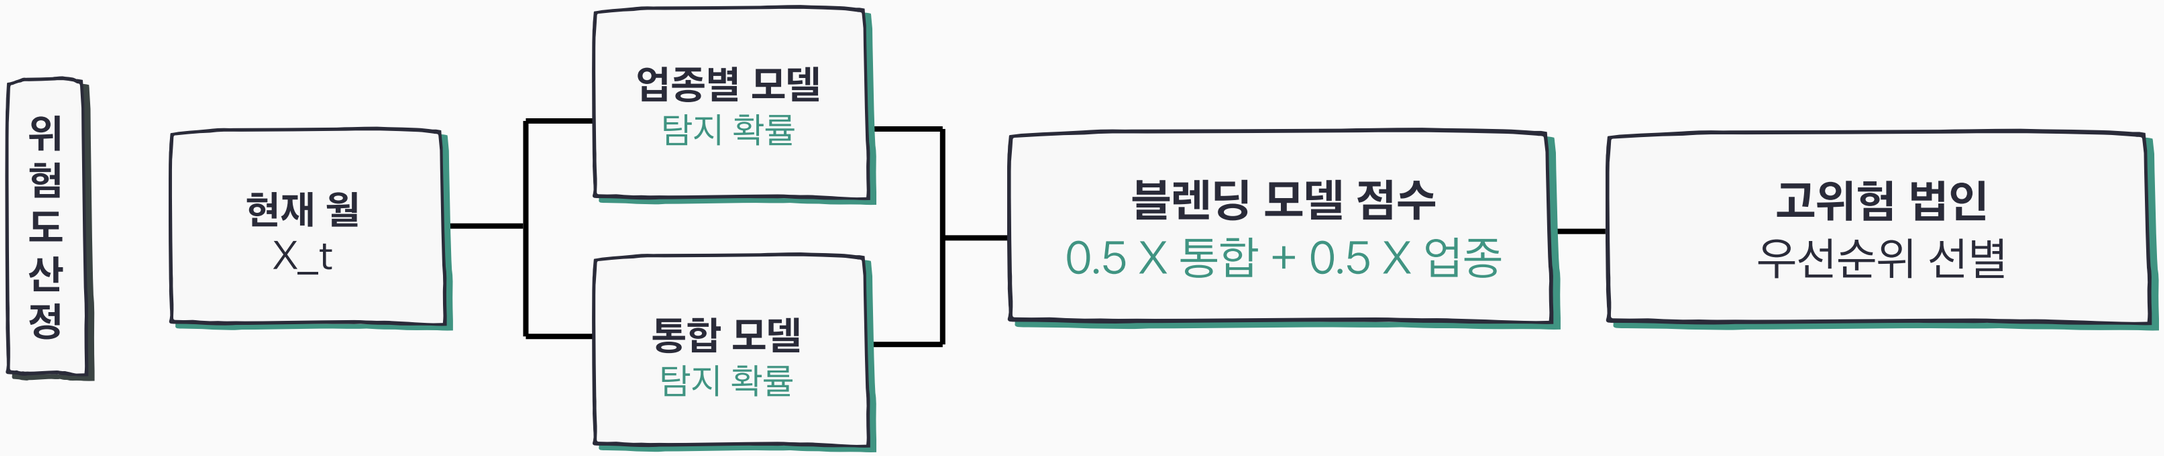
2. 분석 파이프라인



페르소나 분석

3. 블렌딩 모델로 Y_next1 탐지

이 단계의 목적 : 다음 달 활동이 감소할 법인을 줄 세우는 것



페르소나 분석

3. 블렌딩 모델로 Y_next1 탐지

이 단계의 목적 : 다음 달 **활동이 감소할 법인**을 줄 세우는 것



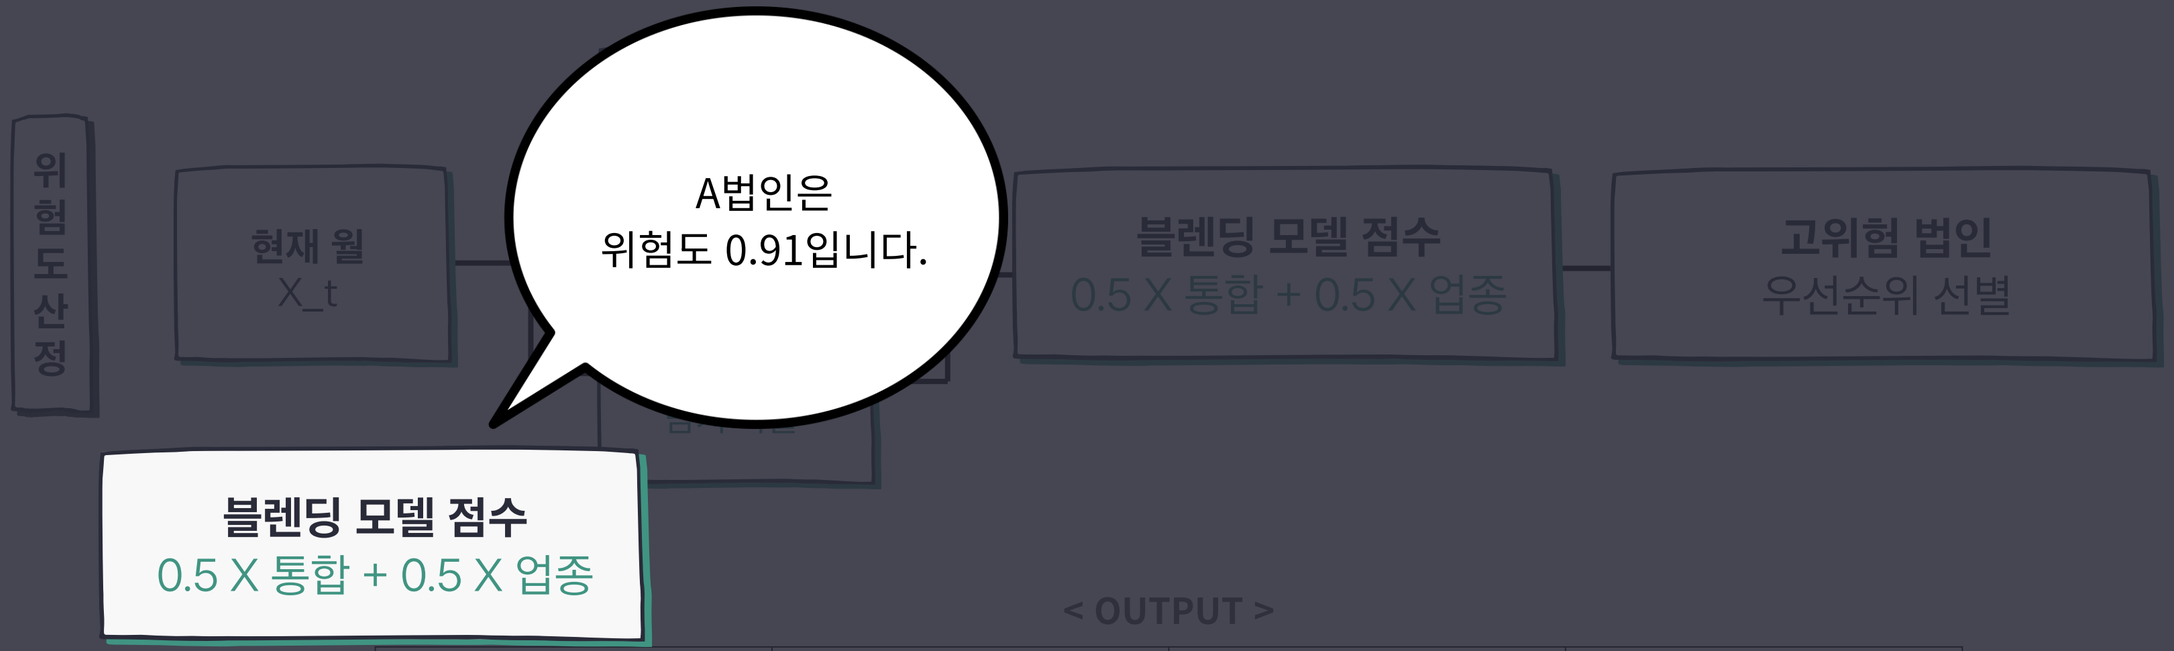
< OUTPUT >

법인ID	기준년월	다음월 위험도	탐지
A	202511	0.91	위험
B	202511	0.74	위험
C	202511	0.21	안정

페르소나 분석

3. 블렌딩 모델로 Y_next1 탐지

이 단계의 목적 : 다음 달 활동이 감소할 법인을 줄 세우는 것



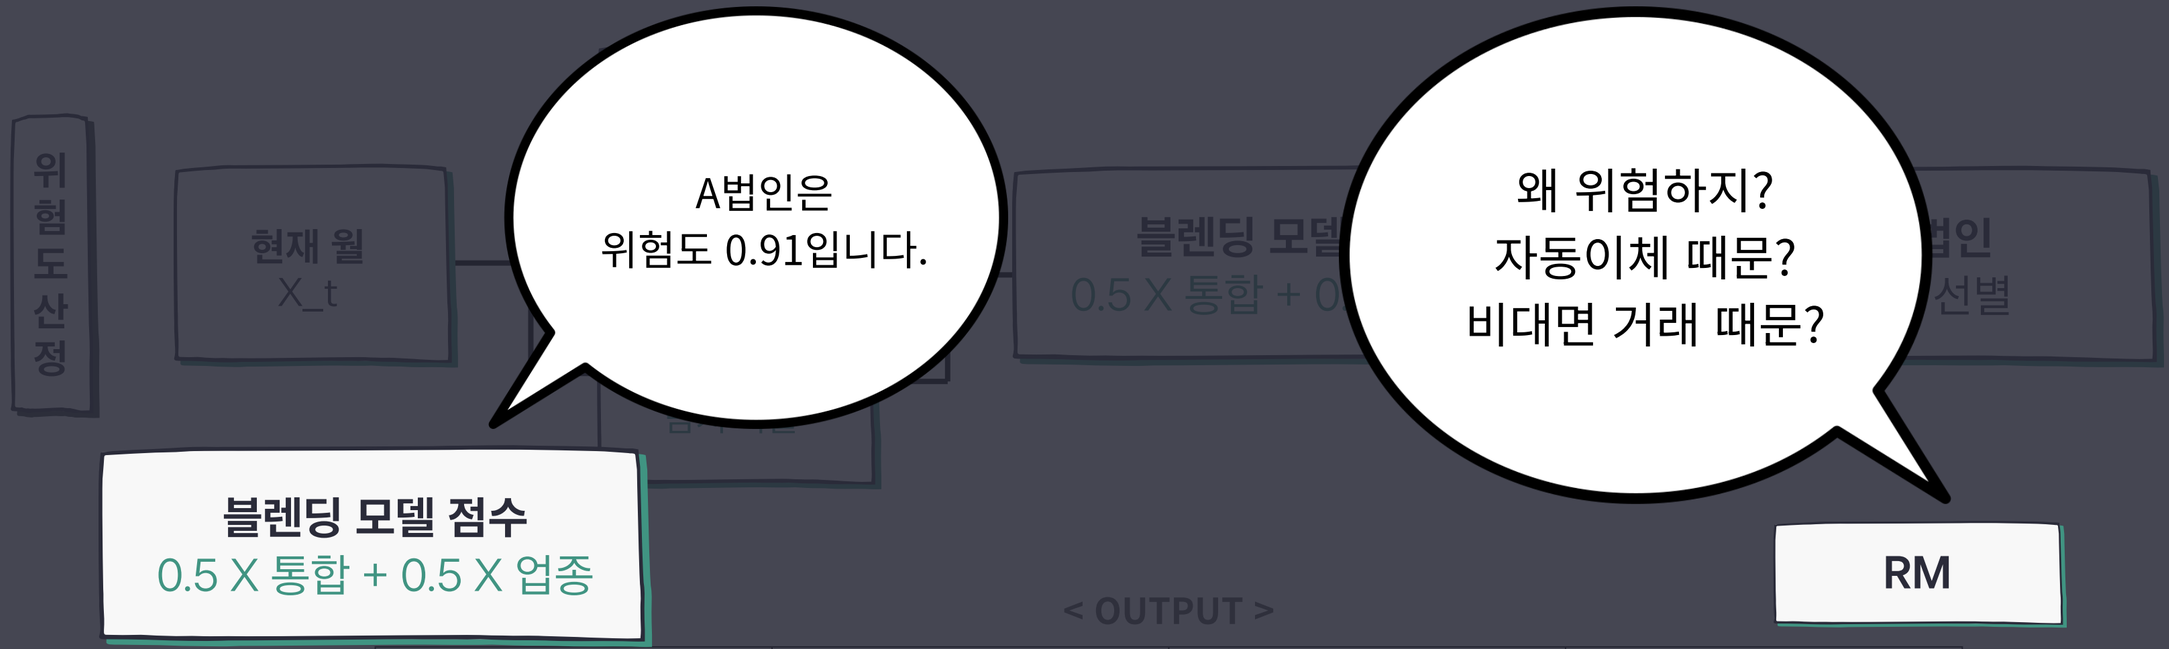
< OUTPUT >

법인ID	기준년월	다음월 위험도	탐지
A	202511	0.91	위험
B	202511	0.74	위험
C	202511	0.21	안정

페르소나 분석

3. 블렌딩 모델로 Y_next1 탐지

이 단계의 목적 : 다음 달 활동이 감소할 법인을 줄 세우는 것



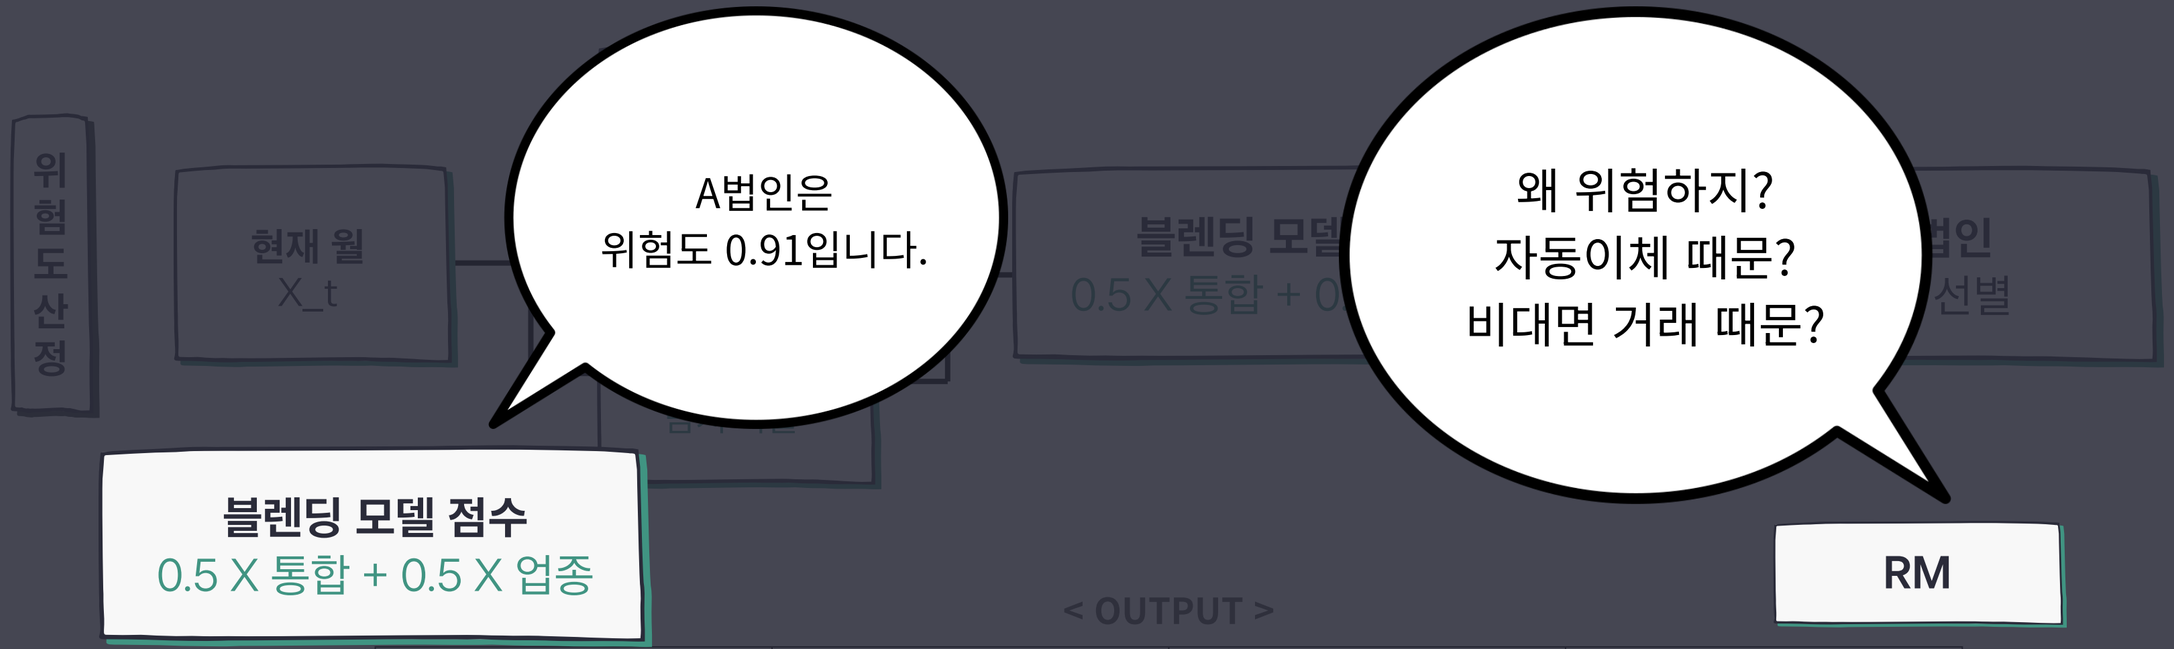
< OUTPUT >

법인ID	기준년월	다음월 위험도	탐지
A	202511	0.91	위험
B	202511	0.74	위험
C	202511	0.21	안정

페르소나 분석

3. 블렌딩 모델로 Y_next1 탐지

이 단계의 목적 : 다음 달 활동이 감소할 법인을 줄 세우는 것



< OUTPUT >

법인ID	기준년월	다음월 위험도	탐지
A	202511	0.91	위험
B	202511	0.74	위험
C	202511	0.21	안정

이에 통합 모델을 통해 SHAP으로 위험 요인 프로필을 생성함

페르소나 분석

3.블렌딩 모델로 Y_next1 탐지

이 단계의 목적 : 다음 달 활동이 감소할 법인을 줄 세우는 것

위험도 산정

현재 월
X_t

블렌딩 모델
0.5 X 통합 + 0

법인
선별

A법인은
위험도 0.91입니다.

왜 위험하지?
자동이체 때문?
비대면 거래 때문?

블렌딩 모델 점수
0.5 X 통합 + 0.5 X 업종

RM

< OUTPUT >

법인ID	기준년월	다음월 위험도	탐지
A	202511	0.91	위험
B	202511	0.74	위험
C	202511	0.21	안정

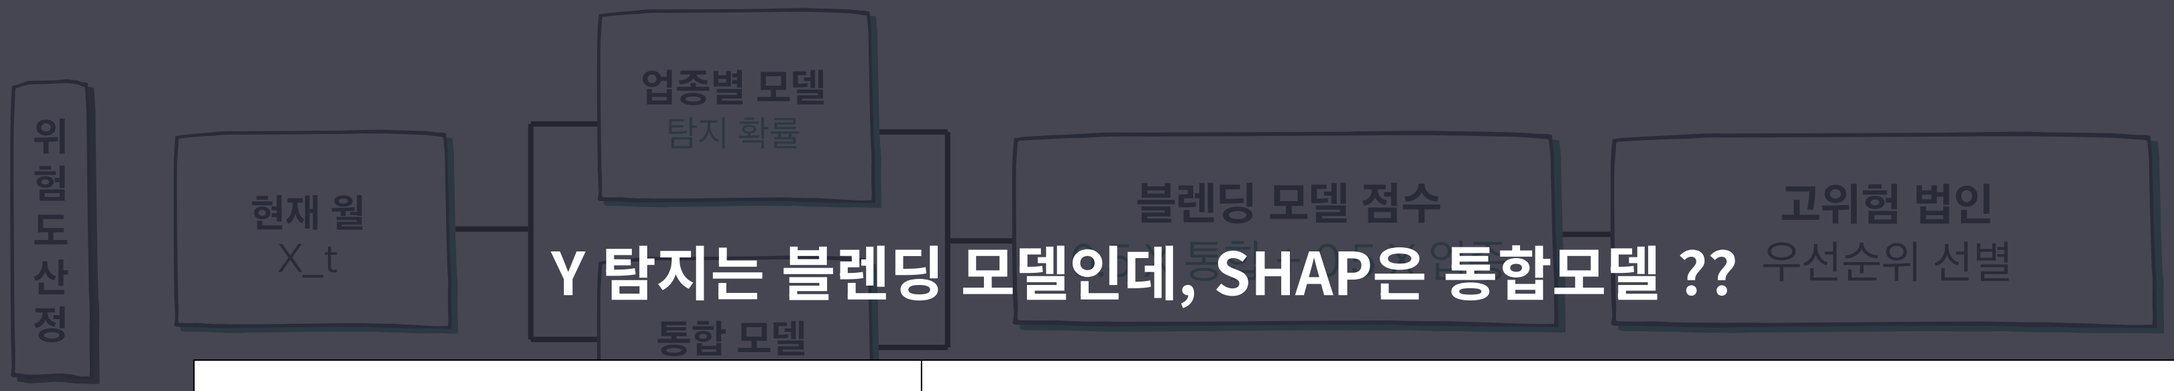
이에 통합 모델을 통해 SHAP으로 위험 요인 프로필을 생성함

Y 탐지는 블렌딩 모델인데, SHAP은 통합모델 ??

페르소나 분석

3. 블렌딩 모델로 Y_next1 탐지

이 단계의 목적 : 다음 달 **활동이 감소할 법인**을 줄 세우는 것



Y 탐지는 블렌딩 모델인데, SHAP은 통합모델 ??

모델 이름	구조
통합모델	모든 법인을 같은 기준으로 설명 가능
업종별모델	업종마다 모델/피처 구조가 다를 수 있음
블렌딩모델	통합 + 업종별 탐지확률 조합이라 단일 SHAP 공간이 아님

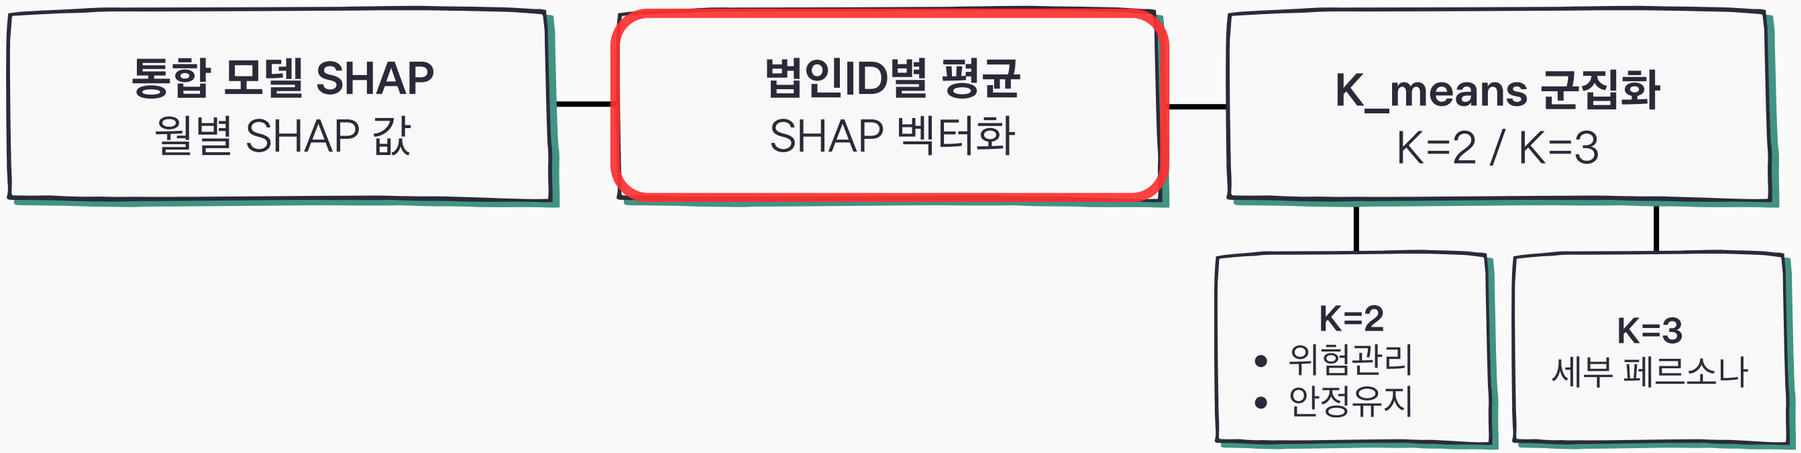
B	202511	0.74	위험
C	202511	0.21	안정

페르소나 분석

4. 통합 모델 SHAP으로 위험요인 프로필 생성

위험요인해석

이 단계의 목적 : 이 법인이 평균적으로 어떤 이유 때문에 위험하다고 판단되는지 숫자 벡터로 만드는 것



페르소나 분석

4. 통합 모델 SHAP으로 위험요인 프로필 생성

위험요인해석

이 단계의 목적 : 이 법인이 평균적으로 어떤 이유 때문에 위험하다고 판단되는지 숫자 벡터로 만드는 것

통합 모델 SHAP

법인ID별 평균

K-means 군집화

< SHAP 벡터화 OUTPUT >

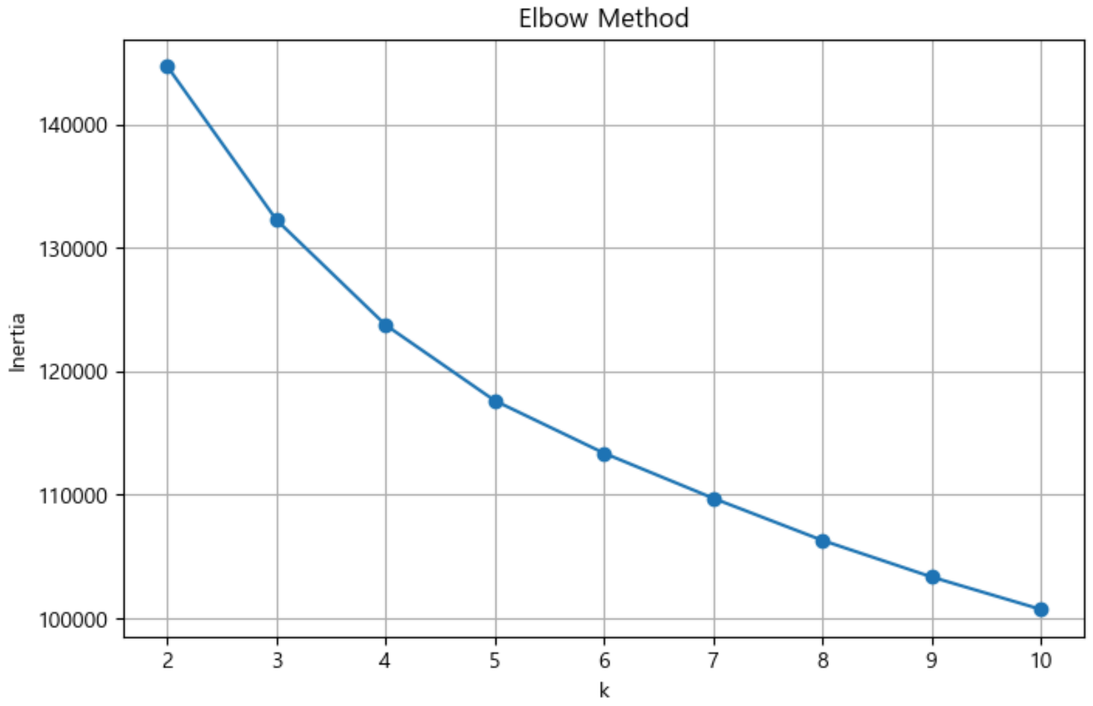
법인ID	기준년월	자동이체 SHAP	총거래금액 SHAP	비대면 SHAP
A	202509	0.12	0.05	-0.01
A	202510	0.18	0.07	0.02
A	202511	0.15	0.09	0.01

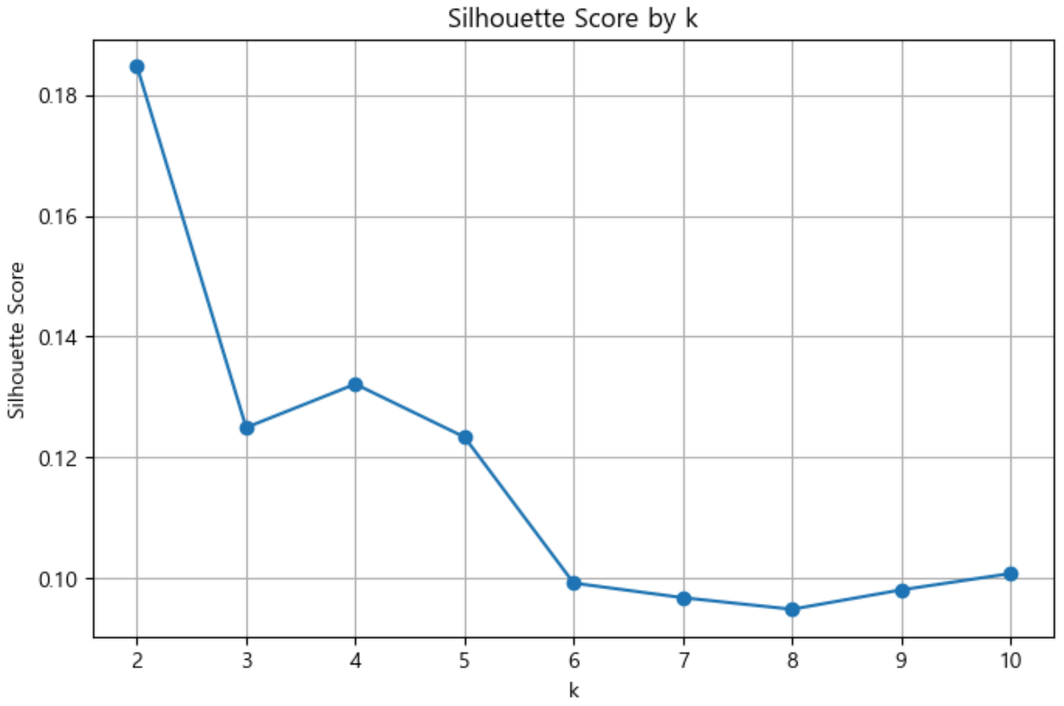
< 법인 A의 위험요인 프로필 OUTPUT >

법인ID	자동이체 평균 SHAP	총거래금액 평균 SHAP	비대면 평균 SHAP
A	0.15	0.07	0.01

페르소나 분석

5. 클러스터링 설계

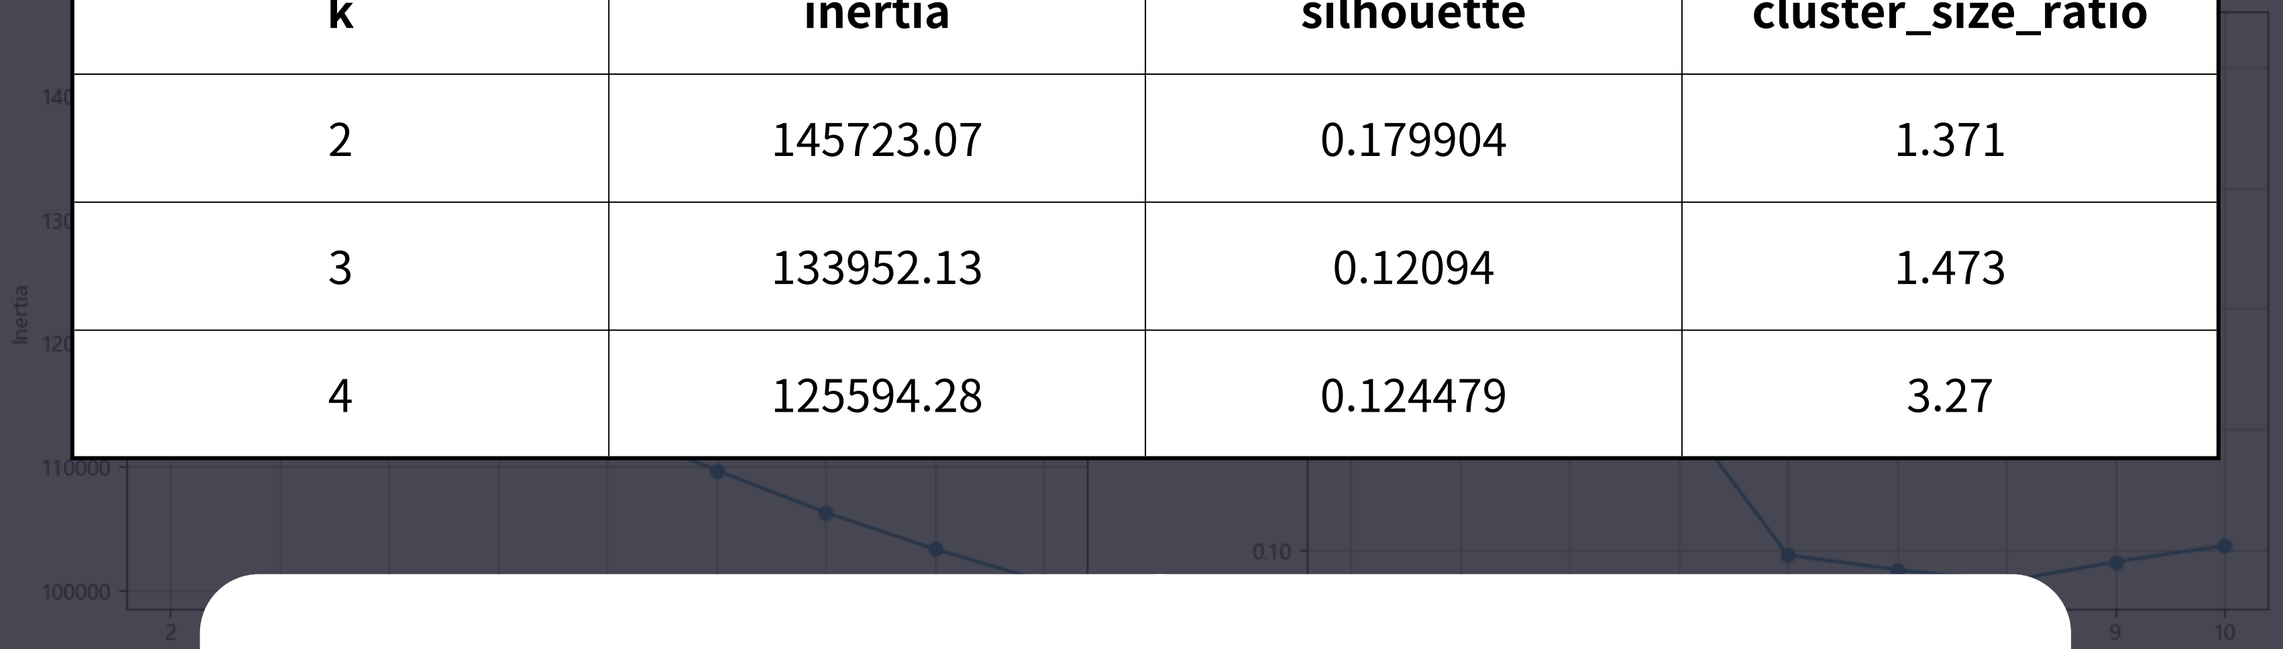




페르소나 분석

5. 클러스터링 설계

k	inertia	silhouette	cluster_size_ratio
2	145723.07	0.179904	1.371
3	133952.13	0.12094	1.473
4	125594.28	0.124479	3.27



정량적으로는 K=2가 적합, 세분화된 설명 측면에서는 K=3적합

페르소나 분석

5.K=2 x K=3 교차 검증 결과

K= 3 페르소나	k=2 안정유지군	k=2 위험관리군	해석
안정 거래 유지 저위험군	**100%**	0%	안정
거래규모 변동성 확대 중위험군	21%	79%	관찰
비대면·자동이체 급변 고위험군	0%	**100%**	위험

저위험군은 모두 안정유지군, 고위험군은 모두 위험관리군에 포함됨

중위험군은 안정과 위험 사이에 위치한 전이/관찰군으로 해석 가능

페르소나 분석

6. 클러스터링 설계: k=2와 k=3의 역할 분리

K=2

1차 위험 게이트

- 정량지표상 가장 안정적
- 위험/비위험 1차 구분
- 판별용

K=3

최종 페르소나 정의

- 해석 가능성 우수
- 안정유지군 / 위험관리군 등 유형화
- 설명용

→ k=2와 k=3 교차표를 통해 두 결과가 정합적인지 확인

K=2 는 “누구를 먼저 볼지” | **K=3 는 “어떻게 관리할지”**

페르소나 분석

7.최종 페르소나 3종

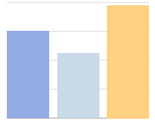


01 안정 유지군

위험도: Low

거래 패턴 안정

→ 관계 유지 / 우량 고객 관리

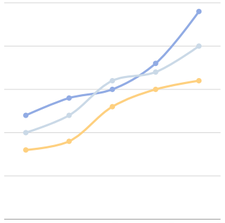


02 변동성 관찰군

위험도: Middle

거래금액·자동이체·비대면 변동 확대

→ 고위험 전이 관찰



03 즉시 관리군

위험도: High

비대면·자동이체·입금 흐름 급변

→ 담당자 개입 / 모니터링

SHAP 기반 페르소나를 통해 위험 고객을 "유지 – 관찰 – 개입" 단계로 구분하였다.

06

제언

페르소나 기반 최종 제의

제언

1. 분석 결과 기반 은행 제언



제언

1. 부동산업 한 법인의 고위험 사례

0.9979
최신월 블렌딩 위험도
매우 높음

위험관리군
k=2 게이트 분류
즉시 모니터링

비대면·자동이체
급변 고위험군
k=3 페르소나

29개월
위험 지속 기간
전 기간 y=1 (100%)

기준년월	통합모델	업종모델	블렌딩	위험수준
2025년 06월	0.9996	0.9998	0.9997	매우 높음
2025년 07월	0.9991	0.9987	0.9989	매우 높음
2025년 08월	0.9980	0.9996	0.9988	매우 높음
2025년 09월	0.9976	0.9996	0.9986	매우 높음
2025년 10월	0.9992	0.9988	0.9990	매우 높음
2025년 11월 ★	0.9963	0.9996	0.9979	매우 높음

6개월 연속 블랜딩 위험도 0.997 이상 유지 — 최신월 0.9979, 위험월 29개월 (전 기간 100%)

제언

2.SHAP 기반 핵심 신호

공통 핵심 변수	통합모델 SHAP	업종모델 SHAP	위험 유형	방향
자동이체금액_CV6	+0.792	+1.154	결제 기반 변동	거래 감소 위험 ▲
자동이체_비중_std3	+1.049	+1.373	결제 기반 변동	거래 감소 위험 ▲
디지털_전환율_ma3	+0.772	+0.344	채널패턴 변화	거래 감소 위험 ▲
인터넷뱅킹거래금액	+0.353	+0.212	거래활동 변동	거래 감소 위험 ▲
자동이체금액_lag1 (통합 단독)	+1.227	—	결제 기반 변동	거래 감소 위험 ▲
총거래금액_lag1 (업종 단독)	—	+0.995	거래활동 변동	거래 감소 위험 ▲

🔎 두 모델 공동 4개

자동이체금액_CV6·자동이체_비중_std3
디지털_전환율_ma3·인터넷뱅킹거래금액
→ 결제·채널 동시 이상 = 구조적 위험

3가지 동시 감지

자동이체 불안정 + 디지털 채널 변동 + 거래 규모 위축

제언

3. 실제 거래 추이

기준년월	총거래금액	자동이체금액	자동이체비중	인터넷뱅킹	디지털전환율	활성채널수
2025년 06월	140	140	100%	0	0	1
2025년 07월	0	0	0%	0	0	0
2025년 08월	0	0	0%	0	0	0
2025년 09월	140	140	100%	0	0	1
2025년 10월	0	0	0%	0	0	0
2025년 11월 ★	0	0	0%	0	0	0

제언

4. RM 확인 조치

위험 유형	실제 거래 확인 결과	RM 즉시 확인 조치
결제 기반 변동 SHAP 최대 +1.373	6개월 중 4개월 거래 없음 발생월(06·09월)도 자동이체 100% 집중 최신월(11월) 자동이체 0 → 완전 소멸	자동이체 등록·해지 이력 확인 정기결제·공과금 계좌 전류 여부
거래활동 변동 SHAP 최대 +0.995	총거래금액 간헐 발생 (6개월 중 2개월) 비대면·인터넷뱅킹 전 기간 0 최신월 거래 전무 → 완전 거래 중단	주거래 계좌 거래 감소 여부 확인 타행 이전 가능성 점검
채널패턴 변화 SHAP +0.772	디지털 전환율 6개월 전체 0 활성채널수 최대 1개 (창구·비대면 모두 0)	인터넷뱅킹 접속 이력 확인 디지털 채널 거래 감소 여부 판단

최신월(202511) 거래 전무 + 6개월 중 4개월 공백 + 비대면·채널 완전 소멸 → **RM 즉시 접촉** 필요

제언

5. 인사이트

01 → 02 → 03 → 04

거래 변동성 증가

- 이탈은 **갑자기 발생하지 않음**
- 완전 이탈 전 거래활동성 약화 신호가 선행됨

- 3~6개월 변동성 지표 관리
- 잔액, 거래빈도,금액 변동성을 조기경보 지표로 활용

최신 월 블렌딩 위험도 산출

- **RM 우선순위** 설정 가능
- 위험도가 높은 고객부터 먼저 확인 가능

- 위험도 구간별 관리
- 0.8 이상 즉시 확인, 0.6~0.8 집중 모니터링

k=2 / k=3 역할 분리

- **관리 대상과 방식 구분**
- 누굴 먼저 볼지와 어떻게 대응할지 함께 제시

- 위험 게이트 + 페르소나 운영
- 위험관리군을 우선 보고, 유형별 대응 차별화

중위험군 존재

- **선제 대응** 가치가 큼
- 고위험이 되기 전 거래 활동성 감소 방어 가능

- 집중 관찰 및 선제 접촉
- 최근 3~6개월 거래 추이를 확인하고 RM이 조기 접촉

07

한계점 및 확장성

한계점 및 향후 개선 방향

한계점 및 확장성

1. 한계점 및 향후 개선 방향

구분	한계점	대응	개선 방향
라벨	실제 이탈이 아닌 거래활동성 약화 proxy	Y 정합성 검증	실제 해지·폐업·주거래 해제 라벨 확보
SHAP	인과관계가 아닌 모델 설명값	최근 거래 추이와 함께 해석	RM 피드백 기반 사후검증
보간	추정값으로 인한 노이즈 가능성	통계 검증 기반으로 중간 랜덤 누락만 사용	보간 신뢰도 score 추가
업종모델	업종별 표본 수 차이	통합모델과 블렌딩 적용	업종별 threshold 및 장기 데이터 확보
페르소나	정답 없는 비지도 유형화	k=2/k=3 교차검증	월별 페르소나 이동·안정성 검증

Q & A

경청해주셔서
감사합니다.



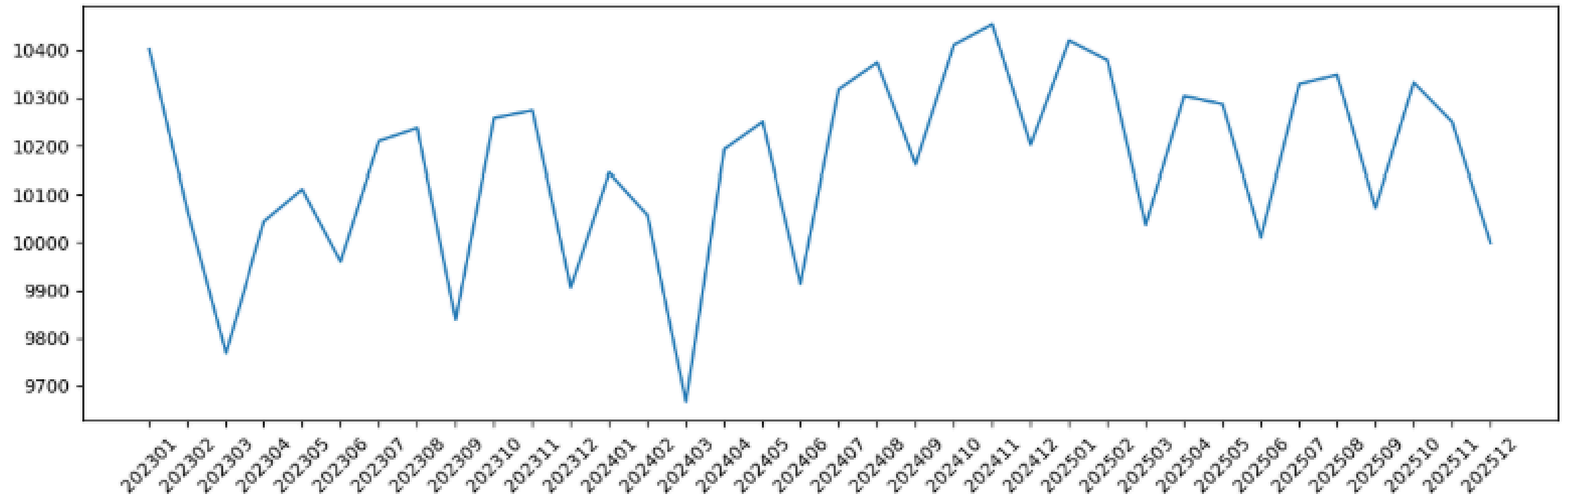
1조 바로이탈잡아뿌조 | 박성준 서은표 이주희 정수민 조준연 차재혁 | 2026.06.25.

참고 자료

참고자료

분기 말마다 활성 고객 수 감소 현상 확인

결과 분기 말에 사라진 고객 중 약 66~75% 수준이 다음 달 재등장하였으며, 평균적으로 약 70% 이상의 고객이 거래를 재개하는 패턴을 보였다.



- **분기 말마다 활성 고객 수 감소 현상 확인**
- **그 중 다수가 다음 달 재등장**
- **단기 거래 공백과 지속적 거래 공백 구분할 필요 확인**
- **ID 카운트 기준**

참고자료

보간 근거 및 논문 출처

comes, missing exposures and missing covariates. A third method, the missing-indicator method, is specifically proposed for missing confounder data in etiologic research.[7,8] This method uses a dummy (1/0) variable in the statistical model to indicate whether the value for that variable is missing, and all missing values are set to the same value. Accordingly, each

1. merged['보간여부'] = merged['법인ID'].isna().astype(int) → **보간여부**

여기서 결측지표법을 "더미(1/0) 변수를 모형에 넣어 그 변수가 결측인지 표시하고,
모든 결측값은 같은 값으로 설정한다"고 정의합니다. → 보간여부

Missing covariate data in clinical research: when and when not to use the missing-indicator method for analysis
Rolf H.H. Groenwold MD PhD, Ian R. White MSc, A. Rogier T. Donders PhD, James R. Carpenter DPhil, Douglas G. Altman DSc, Karel G.M. Moons PhD

1.3.6 LOCF and BOFC

Last observation carried forward (LOCF) and baseline observation carried forward (BOCF) require longitudinal data. The idea is to take the last observed value as a replacement for the missing data. Figure 1.4 illustrates the method applied to the first 80 days of the `Ozone` series. The stretches of red dots indicate the imputations.

2. merged[c] = merged[c].ffill().bfill() → locf

"LOCF는 종단 데이터를 요구한다. 마지막 관측값을 결측의 대체값으로 가져온다."
→ ffill()의 정의 출처.

Flexible Imputation of Missing Data_Stef van Buuren

참고자료

보간 근거 및 논문 출처

3. fillna(ZERO_CNT_LABEL) / fillna(0) → zero_* 0 대체

et al., 2016). All these imputation methods assume that zeros arise from the true absence of taxa (i.e., structural zeros) or a detection limit (i.e., technical zeros). Thus, imputed values are less than a lower limit

1. "이 대체법들은 0이 **참된 부재(structural zero)**나 검출한계(technical zero)에서 발생한다고 가정한다." → 거래 부재 = 참된 부재 = structural zero → 0.

the other represents the existence of a function performed by other taxa. Thus, distinguishing structural zeros from technical or sampling zeros may be impossible, except for a special case where zeros are in all or almost all samples of a subgroup.

2. 따라서, 하위 그룹의 모든 또는 거의 모든 샘플에 0이 있는 특수한 경우를 제외하고는 구조적 0을 기술적 또는 표본 0과 구별하는 것은 불가능할 수 있다.
   → 0이 모호하지 않은 깨끗한 구조적 0이라 0 대체가 타당하다고 판단

A semi-parametric multiple imputation method for high-sparse, high-dimensional, compositional data

Michael B. Sohn1†, Kristin Scheible2,3, and Steven R. Gill

참고자료

보간 근거 및 논문 출처

4.interpolate(method='linear', limit_area='inside') → **선형보간**

For this we first need to create an example input series with missing data.

```
# Create a short example time series with missing values
 x <- ts(c(1, 2, 3, 4, 5, 6, 7, 8, NA, NA, 11, 12))
```

While na.interpolation and all other imputation functions are used the same way, the results produced may be different. As can be seen below, for this series linear interpolation gives more reasonable results.

```
# Impute the missing values with na.interpolation
na.interpolation(x)
```

9·10번이 결측인 시리즈에 na.interpolation(x) → 1 2 3 4 5 6 7 8 9 10 11 12로 내부 구간을 직선으로 메우고, "이 시리즈에선 선형보간이 더 합리적"이라고 본문이 적시.
→ 잔액·한도 보간의 직접 근거.

imputeTS: Time Series Missing Value Imputation in R
by Steffen Moritz and Thomas Bartz-Beielstein

참고자료

보간 근거 및 논문 출처

5. s.round(dec_map.get(c, 0)) → **재라운딩**

1. **Post-imputation rounding**
One option is to impute the missing values using the standard imputation technique (via MICE or MVN imputation) and then round any values that fall outside the observed or possible range to the limits of the range. This method has been applied in a number of methodological and applied studies (see for example, [10-13]).

표준 대체기법(MICE 또는 MVN 대체)으로 결측을 대체한 뒤, 관측 가능하거나 가능한 범위를 벗어난 값을 그 범위의 한계로 라운딩하는 것이며, 이 방법은 여러 방법론·응용 연구에서 적용되어 왔다고 명시

Comparison of methods for imputing limited-range variables: a simulation study
_Laura Rodwell1,2*, Katherine J Lee1,2, Helena Romaniuk1,2,3 and John B Carlin1,

베이스 모델

2.모델링

전체 데이터(36개월)_파생변수, 외부 데이터 추가

```
# ── 합산 ──────────────────────────────────────────────────────────────
dfx['총예금잔액']    = safe_sum(dfx, ['요구불예금잔액','거치식예금잔액','적립식예금잔액'])
dfx['총여신잔액']    = safe_sum(dfx, ['여신_운전자금대출잔액','여신_시설자금대출잔액'])
```

```
# ── 비율 ──────────────────────────────────────────────────────────────
dfx['비대면_비중']    = dfx['비대면거래금액'] / (dfx['총거래금액'] + EPS2)
dfx['카드_비중']      = dfx['총카드사용액']   / (dfx['총거래금액'] + EPS2)
```

```
# ── 플래그 ──────────────────────────────────────────────────────────────
dfx['외환거래여부']    = (dfx['총외환실적'] > 0).astype(int)
dfx['카드사용여부']    = (dfx['총카드사용액'] > 0).astype(int)
```

```
# ── 시계열 파생 (lag/diff/pct/ma/std/accel) ──────────────────────────────
BEHAV_COLS = [c for c in ['총거래금액','비대면거래금액','창구거래금액','자동이체금액',
                          '총카드사용액','총외환실적','인터넷뱅킹거래금액','스마트뱅킹거래금액',
                          '신용카드사용금액','체크카드사용금액','비대면_비중','디지털_전환율',
                          '카드_비중','자동이체_비중'] if c in dfx.columns]
```

```
# ── 채널 다양성 / 카드 / 수출입 ──────────────────────────────────────────
CH = [c for c in ['창구거래금액','인터넷뱅킹거래금액','스마트뱅킹거래금액','폰뱅킹거래금액','ATM거래금액','자동이체금액'] if c in dfx.columns]
```

베이스 모델

2.모델링

전체 데이터(36개월)_파생변수, 외부 데이터 추가

```
# ① 감성지수_전업종
try:
    _sent = pd.read_csv('감성지수_전업종.csv')
```

```
# ② 버즈
try:
    _buzz = pd.read_csv('버즈_전업종중분류.csv')
```

```
# ③ 뉴스감성 인덱스
try:
    with open('model_sentiment_index.csv','rb') as _f: _raw=_f.read()
```

```
# ④ 매크로 (기준금리/환율/CD/국고채)
try:
    _macro = pd.read_csv('macro_indicators.csv')
```

베이스 모델

2.모델링

전체 데이터(36개월)_파생변수, 외부 데이터 추가

```
7  # ── 매크로 x 행동 ──────────────────────────────────────────────
8  if '기준금리' in dfx.columns:
9      _ru = (dfx['기준금리_전월대비'].fillna(0) > 0).astype(float)
```

```
27 # ── 버즈 x 행동 ──────────────────────────────────────────────
```

```
32      _bm['버즈_전월대비']  = gb.diff(1)
33      _bm['버즈_3개월변화'] = gb.diff(3)
```

페르소나 분석

8.개별 법인 진단 구조

최종 위험도 산정	공통 위험요인 도출	업종 특화 위험요인 도출	최종 관리 제언
블렌딩 모델	통합모델 SHAP	업종별 모델 SHAP	공통 + 업종별 요인 종합

위험도는 **블렌딩 모델**로 판단, **통합모델**의 SHAP 해석을 통해
“왜 위험한지”와 “어떻게 관리할지”를 연결